



Conception et développement d'un écosystème data bancaire moderne

De la collecte à la valorisation des données clients

Mémoire de Master 2 en alternance

Réalisé par :

Adam TAIEB

Encadrement :

Tuteur universitaire :

Bénédicte HERRMANN

Tuteur en entreprise :

Jean-Yves BALLOT

Juin 2025

Version publique, octobre 2026 : données personnelles et identifiants internes retirés.

Remerciements

Au terme de ce parcours de Master 2, je souhaite adresser mes plus sincères remerciements à l'ensemble des personnes qui ont rendu possible l'aboutissement de ce mémoire et qui ont marqué cette année déterminante de mon cursus universitaire.

Ma reconnaissance va tout d'abord à Mme. Bénédicte Herrmann, ma directrice de mémoire, dont l'accompagnement rigoureux et les orientations méthodologiques ont été déterminants dans la construction de cette recherche. Son exigence académique, conjuguée à sa bienveillance, m'a permis d'approfondir ma réflexion et de structurer ma démarche scientifique avec la rigueur qu'exige ce niveau d'études.

J'exprime également ma profonde gratitude à M. Jean-Yves Ballot, qui a su me faire confiance en m'intégrant pleinement aux projets stratégiques du Crédit Agricole Franche-Comté. Son mentorat professionnel et sa vision des enjeux sectoriels ont nourri ma compréhension des problématiques contemporaines de l'institution financière. Cette collaboration a constitué un laboratoire d'apprentissage exceptionnel où théorie et pratique se sont enrichies mutuellement.

L'équipe du Crédit Agricole Franche-Comté mérite également toute ma reconnaissance pour la qualité de l'accueil et la richesse des échanges professionnels. Cette immersion au cœur des métiers bancaires a considérablement élargi mes perspectives et affiné ma compréhension des dynamiques organisationnelles.

Mes remerciements s'étendent naturellement à ma famille et à mes proches, dont le soutien constant et la confiance inébranlable ont constitué un socle précieux tout au long de cette année intensive. Leur compréhension face aux exigences de ce parcours et leurs encouragements dans les phases les plus exigeantes ont été essentiels à ma persévérance.

Table des matières

Introduction **7**

1 Contexte organisationnel et infrastructure technique **13**

1 Présentation du Crédit Agricole Franche-Comté et positionnement de l'équipe 13

1.1 Le Crédit Agricole Franche-Comté dans l'écosystème bancaire 13

1.2 L'équipe Data Web Dev : interface entre marketing et technologie 14

2 Contexte sectoriel et transformation digitale du secteur bancaire . . 14

2.1 Mutations du paysage bancaire français 14

2.2 Enjeux réglementaires et contraintes opérationnelles 15

2.3 Opportunités de la valorisation des données 15

3 Infrastructure technique et écosystème technologique 16

3.1 Architecture de sécurité et conformité 17

4 Enjeux et défis de la mission 18

4.1 Problématique centrale et objectifs stratégiques 18

4.2 Défis techniques et méthodologiques 19

4.3 Enjeux méthodologiques spécifiques 19

2 Segmentation client innovante : entre précision algorithmique et interprétabilité métier **21**

1 Introduction : La dualité précision-interprétabilité dans la segmentation bancaire 21

2 Approche *precision-first* : vers une segmentation de potentiel 23

2.1 Architecture de la segmentation socio-démographique *precision-first* . . . 23
2.2 Méthodologie de calcul du potentiel dynamique . . . 27
2.3 Segmentation de potentiel dynamique . . . 31
3 Segmentation interprétable : construction de personas marketing . . . 33
3.1 Approche bidirectionnelle : complémentarité des segmentations socio-démographique et comportementale . . . 33
3.2 Méthodologie de construction des segments socio-démographiques 34
3.3 Paradoxe de l'optimisation métrique versus pertinence métier 35
3.4 Méthodologie de construction des segments comportementaux 37
3.5 Méthodologie de segmentation comportementale . . . 37
3.6 Analyse socio-démographique enrichie par les comportements MCC . . . 41
3.7 Analyse comportementale enrichie par les profils socio-démographiques 46
3.8 Synthèse des insights bidirectionnels . . . 49
4 Synthèse : La complémentarité des approches au service d'usages distincts . . . 50
4.1 Limites méthodologiques de l'approche croisée et biais de sélection . . . 50
4.2 La pertinence de maintenir deux approches distinctes . . . 51
4.3 Articulation opérationnelle : des cas d'usage complémentaires 51
4.4 Perspectives : vers une approche modulaire de la segmentation 52

3 Développement de l'application web 360° 53
1 L'enjeu stratégique : connecter la data au terrain . . . 54
1.1 Le fossé historique entre analytics et opérationnel . . . 54
1.2 La ligne de vie comme cheval de Troie . . . 54
2 Architecture technique et contraintes . . . 54
2.1 Contraintes d'infrastructure héritée . . . 54
2.2 Architecture applicative hybride . . . 55
2.3 Intégration avec SQL Server . . . 56
3 Développement des fonctionnalités . . . 56
3.1 Page de recherche avancée . . . 56

3.2 Dashboard client 360° 58
4 Déploiement et adoption 59
4.1 Stratégie de déploiement 59
4.2 Enseignements de la phase test 60
4.3 Accompagnement au changement 60
4.4 Monitoring et analyse d'usage 60
5 Perspectives d'évolution 62
5.1 Intégration des scores de machine learning 62
5.2 Évolutions fonctionnelles envisagées 62
5.3 Modernisation progressive de l'infrastructure 62

4 Gestion de projet et évolution des priorités 64
1 Méthodologie agile adaptée au contexte bancaire 64
1.1 Cycles itératifs courts et validation continue 64
1.2 Priorisation par la valeur métier immédiate 65
2 Gestion des contraintes et adaptation du périmètre 65
2.1 Navigation entre ambitions et réalités techniques 65
2.2 Évolution des priorités organisationnelles 66
3 Pilotage et communication du projet 66
3.1 Instances de gouvernance et reporting 66
3.2 Gestion du changement et accompagnement 66

5 Compétences métiers mises en œuvre 67
1 Compétences en science des données et intelligence artificielle 67
1.1 Maîtrise de l'écosystème Big Data distribué 67
1.2 Techniques avancées de machine learning en contexte contraint 68
2 Compétences en développement et architecture logicielle 68
2.1 Full-stack development en environnement hétérogène 68
2.2 Sécurité et conformité en milieu bancaire 69
3 Compétences métier et soft skills 69
3.1 Compréhension approfondie du domaine bancaire 69
3.2 Médiation entre mondes techniques et métiers 69
3.3 Leadership et conduite du changement 70

6 Bilan et perspectives **71**

1 Bilan des réalisations et impacts mesurés 71

1.1 Objectifs atteints et valeur créée 71

1.2 Transformation culturelle amorcée 72

2 Limites identifiées et axes d'amélioration 72

2.1 Limites techniques et méthodologiques 72

2.2 Limites organisationnelles 72

3 Perspectives d'évolution et recommandations 73

3.1 Roadmap technique à court terme 73

3.2 Vision stratégique à moyen terme 73

3.3 Apport personnel et projection professionnelle 73

Bibliographie **75**

Table des figures

1.1 Vue d'ensemble de l'architecture Big Data CA-TS 16

2.1 Architecture duale permettant de concilier performance algorithmique et adoption métier 22
2.2 Architecture en deux étapes : stratification d'âge puis clustering adaptatif 24
2.3 Pipeline de prétraitement des variables 25
2.4 Métriques de qualité du clustering K-means socio-démographique . 36
2.5 Profil détaillé du segment 18-30 ans 41
2.6 Profil détaillé du segment 30-50 ans 43
2.7 Profil détaillé du segment 50-65 ans 44
2.8 Profil détaillé du segment 65+ ans 45
2.9 Profil détaillé du segment Famille 46
2.10 Segmentation MCC avec composition socio-démographique 47

3.1 Parcours 360 : Page Recherche 58
3.2 Parcours 360 : Page Client 59

Introduction

La transformation digitale du secteur bancaire constitue aujourd'hui un enjeu stratégique majeur face à l'évolution des attentes clients et à l'intensification de la concurrence. Dans ce contexte de mutation profonde, la capacité des établissements bancaires à exploiter intelligemment leurs données clients devient un facteur déterminant de performance. Cependant, cette ambition se heurte souvent à la réalité des infrastructures existantes et aux contraintes organisationnelles héritées de décennies d'évolution technologique progressive.

C'est dans ce cadre que s'inscrit mon alternance de Master 2 au sein du Crédit Agricole Franche-Comté, où j'ai eu l'opportunité d'explorer concrètement les défis de la valorisation des données bancaires. Cette mission, à l'intersection entre innovation algorithmique et pragmatisme opérationnel, m'a confronté à une problématique centrale : comment transformer un patrimoine de données riche mais sous-exploité en leviers d'action concrets pour les équipes commerciales et marketing ?

Ce mémoire retrace le parcours de cette transformation à travers trois axes principaux. Le premier chapitre établit le contexte organisationnel et technique, révélant les contraintes d'une infrastructure hybride où coexistent systèmes legacy et technologies Big Data modernes. Cette dualité technologique, loin d'être un frein, s'est révélée être un terrain d'apprentissage particulièrement formateur pour développer des solutions innovantes dans un environnement contraint.

Le deuxième chapitre présente l'approche méthodologique développée pour la segmentation client, illustrant comment la dualité entre précision algorithmique et interprétabilité métier a conduit à concevoir deux systèmes complémentaires. Cette approche novatrice démontre qu'il n'existe pas de solution universelle en data science, mais plutôt des réponses adaptées à des besoins spécifiques.

Le troisième chapitre détaille le développement de l'application web Parcours 360°, conçue comme un pont entre l'intelligence data et les utilisateurs finaux. Au-delà des aspects techniques, ce projet illustre l'importance cruciale de l'adoption utilisateur et de la conduite du changement dans la réussite d'une initiative data-driven.

Les chapitres suivants abordent les dimensions transversales de cette mission : la gestion de projet en environnement agile adapté au contexte bancaire, et l'ensemble des compétences mobilisées, depuis les aspects techniques du machine learning jusqu'aux soft skills nécessaires à la transformation digitale.

Ce mémoire se veut ainsi le témoignage d'une année d'apprentissage intense, où la confrontation avec les réalités du terrain a enrichi et nuancé ma vision théorique de la data science. Il illustre comment, dans un secteur traditionnel comme la banque régionale, l'innovation ne réside pas tant dans la sophistication technologique que dans la capacité à créer des ponts entre mondes techniques et métiers, entre ambitions data-driven et contraintes opérationnelles.

Glossaire des termes techniques

Ce glossaire recense les termes techniques, acronymes et concepts spécialisés utilisés dans ce mémoire. Il est organisé en deux sections : les acronymes et sigles, puis les concepts techniques, chacune classée par ordre alphabétique.

Acronymes et sigles

ACP *Analyse en Composantes Principales* – Technique de réduction dimensionnelle qui transforme des variables corrélées en composantes principales non corrélées

API *Application Programming Interface* – Interface de programmation permettant à des applications de communiquer entre elles

CATS *Crédit Agricole Technologies Services* – Entité du groupe Crédit Agricole mutualisant les services informatiques

CDO *Chief Data Officer* – Directeur des données, responsable de la stratégie data d'une organisation

CSP *Catégorie Socio-Professionnelle* – Classification INSEE des individus selon leur activité professionnelle

DAV *Dépôts À Vue* – Comptes bancaires permettant des retraits et dépôts sans préavis

JCEKS *Java Cryptography Extension KeyStore* – Format de stockage sécurisé pour clés et certificats cryptographiques

KPI *Key Performance Indicator* – Indicateur clé de performance mesurant l'efficacité d'une action

MAD *Median Absolute Deviation* – Mesure robuste de dispersion statistique résistante aux valeurs aberrantes

MCC *Merchant Category Code* – Code à 4 chiffres classifiant les commerçants par type d'activité

MIRE *Mesure de l'Intensité RElationnelle* – Score propriétaire évaluant l'engagement d'un client avec la banque

PNB *Produit Net Bancaire* – Équivalent du chiffre d'affaires pour une banque

POC *Proof of Concept* – Démonstration de faisabilité d'un concept ou d'une idée

PSD2 *Payment Services Directive 2* – Directive européenne sur les services de paiement

RGPD *Règlement Général sur la Protection des Données* – Réglementation européenne sur la protection des données personnelles

SAS *Statistical Analysis System* – Suite logicielle d'analyse statistique

SID *Système d'Information Décisionnel* – Infrastructure de stockage et traitement des données à des fins analytiques

SSO *Single Sign-On* – Méthode d'authentification unique permettant d'accéder à plusieurs applications

SSR *Server-Side Rendering* – Rendu côté serveur des applications web

SSL/TLS *Secure Sockets Layer / Transport Layer Security* – Protocoles de sécurisation des communications réseau

Concepts techniques

Approche agile Méthodologie de gestion de projet favorisant l'adaptation continue et les livraisons itératives

Backend Partie serveur d'une application gérant la logique métier, les données et l'authentification

Batch mensuel Traitement automatisé exécuté une fois par mois pour actualiser les données

Batch processing Traitement par lots – Exécution groupée de tâches sans interaction utilisateur

Big Data Ensemble de données volumineux nécessitant des technologies spécifiques pour leur traitement

Broadcast (Spark) Technique d'optimisation distribuant une petite donnée à tous les nœuds de calcul

Cache (informatique) Stockage temporaire de données pour accélérer les accès ultérieurs

Chief Data Officer Dirigeant responsable de la gouvernance et de la valorisation des données

Cloud-native Applications conçues spécifiquement pour tirer parti des architectures cloud

Clustering Technique d'apprentissage non supervisé regroupant des données similaires

Coefficient de silhouette Métrique évaluant la qualité d'un clustering (échelle de -1 à 1)

Compilation statique Génération de fichiers HTML/JS/CSS sans nécessiter de serveur d'exécution

Cycles itératifs Approche de développement par phases courtes avec validation continue

Data mining Extraction de connaissances à partir de grandes bases de données

Data product manager Responsable produit spécialisé dans les solutions data-driven

Data steward Responsable de la qualité et de la gouvernance des données

DataFrame Structure de données tabulaire utilisée dans Spark et pandas

Davies-Bouldin Indice de Davies-Bouldin – Métrique de qualité du clustering (plus la valeur est basse, meilleure est la qualité)

Defense-in-depth Défense en profondeur – Stratégie de sécurité utilisant plusieurs couches de protection

Frontend Partie client d'une application gérant l'interface utilisateur

Frontalier Travailleur résidant en France mais exerçant en Suisse (contexte spécifique à la Franche-Comté)

Full-stack development Développement couvrant l'ensemble des couches applicatives (frontend + backend)

Ground truth Données de référence validées servant à évaluer la performance d'un modèle

Hyperparamètres Paramètres d'un modèle ML fixés avant l'entraînement (ex : nombre de clusters)

K-means Algorithme de clustering partitionnant les données en K groupes

Kerberos Protocole d'authentification réseau par tickets chiffrés

Legacy Système legacy – Système informatique ancien mais toujours en production

Machine learning Apprentissage automatique – Ensemble de méthodes permettant aux systèmes d'apprendre à partir des données

MiniBatchKMeans Variante optimisée de l'algorithme K-means traitant les données par petits lots

One-Hot encoding Encodage one-hot – Transformation de variables catégorielles en vecteurs binaires

Outlier Valeur aberrante – Observation s'écartant significativement de la distribution statistique

Persona Représentation fictive et archétypale d'un segment de clientèle

Quick wins Victoires rapides – Résultats tangibles obtenus rapidement pour créer de la dynamique

React Context API Mécanisme React de gestion d'état global sans bibliothèque externe

Sandbox Environnement isolé pour tester en toute sécurité

Scalabilité Capacité d'un système à gérer une charge croissante

Score de Calinski-Harabasz Métrique de qualité du clustering (plus la valeur est élevée, meilleure est la qualité)

Shuffle (Spark) Redistribution coûteuse de données entre nœuds dans un cluster

StandardScaler Technique de normalisation centrant et réduisant les données

Teradata Système de gestion de base de données relationnelle orienté entrepôt de données

Versioning Gestion de versions – Suivi et contrôle des modifications successives d'un code ou document

Chapitre 1

Contexte organisationnel et infrastructure technique

Ce premier chapitre établit le cadre de cette mission d'alternance en présentant l'environnement dans lequel s'inscrit ce projet de valorisation des données bancaires. Après avoir situé le Crédit Agricole Franche-Comté et l'équipe Data Web Dev au sein de l'écosystème bancaire français, nous analyserons les mutations du secteur qui motivent cette démarche d'innovation. Nous détaillerons ensuite l'infrastructure technique qui constitue le terrain d'expérimentation de nos développements, avant de définir précisément les enjeux et défis de cette mission.

1 Présentation du Crédit Agricole Franche-Comté et positionnement de l'équipe

1.1 Le Crédit Agricole Franche-Comté dans l'écosystème bancaire

Le Crédit Agricole Franche-Comté, banque régionale du groupe Crédit Agricole, dessert un territoire de 400 000 clients répartis sur les départements du Doubs, du Jura et de la Haute-Saône. Cette caisse régionale s'appuie sur l'infrastructure technologique du groupe Crédit Agricole Technologies Services (CATS), qui mutualise les investissements informatiques pour l'ensemble des 39 caisses régionales.

Cette architecture mutualisée permet de bénéficier d'innovations technologiques de pointe tout en maîtrisant les coûts de développement et de maintenance.

1.2 L'équipe Data Web Dev : interface entre marketing et technologie

L'équipe Data Web Dev, composée de 8 collaborateurs, occupe une position stratégique au sein de la Direction Marketing de la caisse régionale. Cette équipe hybride, dirigée par mon maître d'apprentissage, associe des compétences complémentaires en développement *web*, analyse comportementale et *data mining*.

D'un côté, la proximité avec les équipes marketing facilite l'identification des besoins réels, de l'autre, l'expertise technique interne garantit la faisabilité des intégrations dans l'écosystème existant et assure la maintenance des solutions déployées.

2 Contexte sectoriel et transformation digitale du secteur bancaire

Le secteur bancaire français traverse aujourd'hui une période de transformation sans précédent, qui redéfinit les modèles économiques traditionnels et contraint les établissements à repenser leur approche client. Cette section analyse les principales forces de mutation qui motivent notre démarche d'innovation data et qui constituent le contexte stratégique de cette mission.

2.1 Mutations du paysage bancaire français

La digitalisation des services financiers constitue l'une des principales forces de disruption du secteur. Les clients, habitués aux interfaces intuitives des géants technologiques, attendent désormais des services bancaires une expérience utilisateur similaire : instantanéité, personnalisation, disponibilité permanente. Cette évolution des attentes consommateurs contraint les établissements traditionnels à repenser leurs parcours clients et leurs processus internes.

Parallèlement, l'émergence des *fintechs* et des *néobanques* intensifie la pression concurrentielle sur des segments spécifiques. Ces acteurs, libérés du poids de l'infrastructure *legacy*, proposent des services ciblés avec une agilité que les banques traditionnelles peinent à égaler. Cette concurrence frontale sur certains produits (moyens de paiement, épargne digitale, crédit instantané) érode progressivement les marges sur les activités historiquement rentables.

2.2 Enjeux réglementaires et contraintes opérationnelles

L'environnement réglementaire bancaire, particulièrement exigeant depuis la crise de 2008, impose des contraintes supplémentaires sur l'usage des données clients. La mise en application du RGPD en 2018, complétée par les directives PSD2 sur les services de paiement, encadre strictement la collecte, le traitement et le partage des informations personnelles.

Ces contraintes juridiques influencent directement les choix architecturaux et fonctionnels des systèmes d'information bancaires. Chaque traitement de données doit s'inscrire dans un cadre de finalité explicite, limitée et légitime, complexifiant le développement de solutions analytiques avancées tout en ouvrant des opportunités pour les établissements capables de maîtriser ces enjeux.

2.3 Opportunités de la valorisation des données

Malgré ces contraintes, l'exploitation intelligente du patrimoine data constitue un levier stratégique majeur pour les établissements bancaires. La richesse des données transactionnelles, comportementales et relationnelles offre des perspectives inédites de personnalisation des offres et d'optimisation de l'expérience client.

La capacité à transformer ces données en *insights* actionnables devient un facteur différenciant déterminant. Les banques qui maîtrisent cette transformation peuvent proposer des services proactifs, anticiper les besoins clients et optimiser leurs processus internes pour améliorer leur rentabilité. Cette transformation nécessite cependant une approche méthodologique rigoureuse et des infrastructures techniques adaptées.

3 Infrastructure technique et écosystème technologique

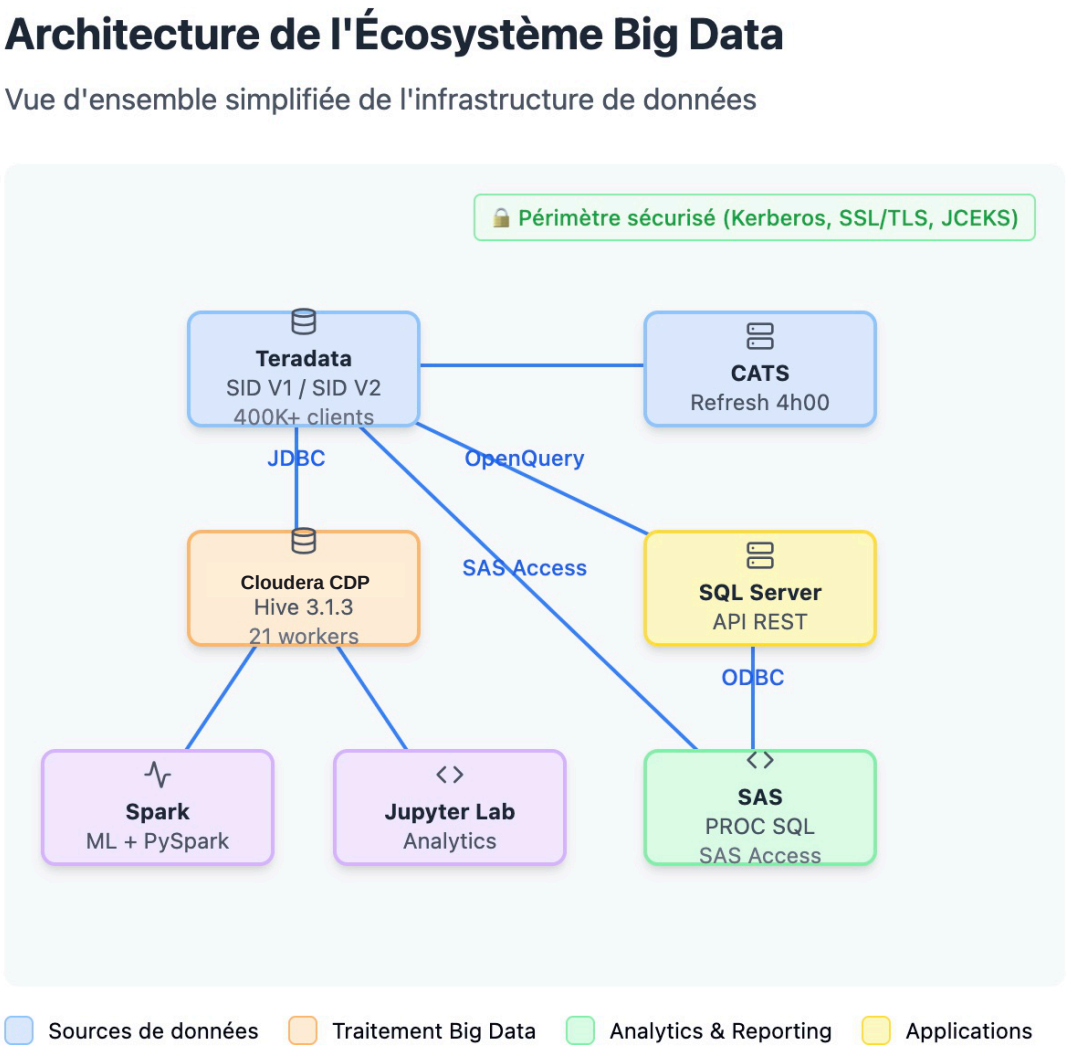


FIGURE 1.1 – Vue d'ensemble de l'architecture Big Data CA-TS

L'infrastructure du Crédit Agricole Franche-Comté s'appuie sur l'écosystème CATS (Crédit Agricole Technologies Services), qui mutualise les investissements technologiques à l'échelle du groupe. Cette approche hybride combine systèmes

legacy éprouvés et technologies *Big Data* modernes pour assurer continuité opérationnelle et capacités d'innovation, comme le synthétise la Figure 1.1.

Environnement traditionnel et contraintes existantes

L'infrastructure Teradata centralise les données de production pour plus de 400 000 clients via deux environnements distincts :

— **SID V1** (nom interne retiré) : Héberge les copies brutes des systèmes de production avec nomenclature technique d'origine

— **SID V2** (nom interne retiré) : Propose une restructuration avec nomenclature métier et modèles dimensionnels optimisés

SAS Enterprise assure les traitements analytiques via des connexions natives SAS/ACCESS *Interface*, tandis que les applications *web* s'appuient sur SQL Server avec capacités *openquery* vers Teradata. Apache HTTP Server héberge les interfaces utilisateurs pour plus de 1000 utilisateurs métier.

Plateforme Big Data : architecture distribuée

La plateforme Cloudera (nom retiré) constitue le cœur de l'infrastructure de traitement massif avec une architecture distribuée sur 21 nœuds de calcul répartis sur 3 sites (codes retirés) et 3 nœuds maîtres en haute disponibilité.

Stack technique :

— **Hive 3.x** : Requêtage SQL-like pour traitements *batch*

— **Spark 2.x** : Traitement parallèle et *machine learning*

— **Jupyter Lab** : Environnement de développement analytique

3.1 Architecture de sécurité et conformité

Le périmètre sécurisé implémente une approche *defense-in-depth* respectant les exigences bancaires :

— **Authentification Kerberos** : Ce protocole d'authentification mutuelle évite la transmission de mots de passe en clair sur le réseau. Ainsi, il délivre des tickets chiffrés permettant aux services de s'authentifier entre eux de manière sécurisée, éliminant ainsi les risques d'interception d'identifiants.

— **Chiffrement SSL/TLS** : Tous les échanges réseau sont chiffrés pour garantir la confidentialité et l'intégrité des données en transit. Cette couche protège contre l'écoute passive et les attaques man-in-the-middle, particulièrement critiques lors des transferts de données financières sensibles.

— **Gestion des credentials via JCEKS** : Le Java Cryptography Extension KeyStore centralise et chiffre tous les mots de passe, clés et certificats utilisés par les applications. Cette approche évite le stockage d'identifiants en dur dans le code source et permet une rotation sécurisée des credentials.

Cette architecture garantit la traçabilité complète des accès et la conformité RGPD avec séparation logique des responsabilités entre couches : sources de données, traitement *Big Data*, *analytics* et applications.

4 Enjeux et défis de la mission

Cette dernière section synthétise les enjeux stratégiques et défis techniques qui structurent cette mission, en définissant précisément la problématique centrale et les objectifs poursuivis. Elle établit également le cadre méthodologique qui guidera nos développements dans les chapitres suivants.

4.1 Problématique centrale et objectifs stratégiques

La problématique centrale de cette mission s'articule autour de la question suivante : "Comment transformer les données bancaires en outils d'aide à la décision pour le service Marketing et pour les conseillers clients ?"

Cette mission poursuit un triple objectif stratégique :

1. **Innovation algorithmique sous contrainte** : Développer des algorithmes de *machine learning* adaptés aux outils disponibles et aux spécificités bancaires
2. **Intégration harmonieuse** : Créer des solutions opérationnelles s'intégrant dans l'architecture existante sans refonte structurelle
3. **Création de valeur métier** : Générer des bénéfices mesurables pour les utilisateurs finaux malgré les limitations techniques

4.2 Défis techniques et méthodologiques

Défi de performance et scalabilité

Le traitement de volumes importants (400 000+ clients, 5 millions+ de contrats) impose des contraintes de performance strictes. L'optimisation doit porter sur la parallélisation des calculs distribués, l'optimisation des requêtes SQL complexes, la mise en *cache* intelligente des résultats, et la minimisation des transferts de données.

Défi de l'acculturation technologique

La transition vers les technologies *Big Data* nécessite une acculturation collective de l'équipe : apprentissage de nouveaux langages (Python, Spark, SQL distribué), appropriation de nouveaux paradigmes (programmation distribuée, traitement par lots), compréhension de l'écosystème distribué, et développement de bonnes pratiques (*versioning*, documentation, tests).

4.3 Enjeux méthodologiques spécifiques

Segmentation client innovante

Le développement d'approches de *clustering* adaptées aux contraintes bancaires constitue un enjeu méthodologique majeur. Deux approches complémentaires seront développées :

— **Approche *precision-first*** : Optimisation de la précision pour le calcul de potentiel PNB (Produit Net Bancaire, c'est-à-dire le chiffre d'affaires que génère chaque client sur l'année glissante) via segmentation par âge et réduction dimensionnelle

— **Approche *interprétabilité-first*** : Optimisation de l'interprétabilité pour la création de *personas* actionables par les équipes commerciales

Prédiction de potentiel contextualisée

Le développement d'un moteur prédictif de potentiel PNB nécessite une approche contextualisée prenant en compte les spécificités socio-démographiques et

comportementales de chaque segment client. Cette approche doit garantir des prédictions à la fois précises et explicables pour les conseillers.

Intégration dans l'écosystème applicatif

Le développement de l'application web *Parcours 360°* introduit des enjeux spécifiques d'intégration avec les systèmes existants. Ce projet doit concilier :

— **Accessibilité des données** : Concevoir des API performantes pour agréger en temps réel les données dispersées dans différents silos

— **Expérience utilisateur unifiée** : Maintenir des temps de réponse inférieurs à 2 secondes malgré la complexité des traitements sous-jacents

— **Sécurité des accès** : Garantir un contrôle d'accès granulaire conforme aux normes bancaires, tout en permettant une utilisation fluide sur le terrain

Conclusion

Ce premier chapitre a établi le cadre de notre mission en révélant une problématique centrale : comment transformer un patrimoine de données riche mais dispersé en leviers d'action concrets pour les équipes commerciales, tout en respectant les contraintes d'une infrastructure héritée et d'un cadre réglementaire strict ?

L'analyse du contexte bancaire régional et de l'écosystème technique hybride du Crédit Agricole Franche-Comté nous a permis d'identifier les défis méthodologiques et les opportunités qui structureront notre approche. Cette triple réalité opérationnelle - transformation sectorielle, contraintes techniques, et exigences métier - constitue le socle sur lequel s'appuieront les développements présentés dans les chapitres suivants.

Nous pouvons désormais aborder la dimension méthodologique de notre travail, en commençant par la conception d'une approche de segmentation client innovante adaptée aux spécificités bancaires.

Chapitre 2

Segmentation client innovante : entre précision algorithmique et interprétabilité métier

Dans ce chapitre, nous aborderons comment, à travers des concepts statistiques, on arrive à créer des segmentations et des KPI (Key Performance Indicators) permettant aux décideurs et aux équipes d'évaluer l'efficacité de leurs actions.

Les solutions présentées résultent d'une approche itérative que j'ai proposée et développée tout au long de ma mission. Plutôt que de concevoir un système monolithique, j'ai privilégié une démarche incrémentale permettant une validation continue avec les équipes métier à travers des cycles courts de développement-présentation-ajustement.

1 Introduction : La dualité précision-interprétabilité dans la segmentation bancaire

La segmentation client constitue un enjeu stratégique majeur pour les établissements bancaires, permettant d'optimiser les approches commerciales et de personnaliser la relation client. Cependant, les praticiens font face à un dilemme fondamental : privilégier la précision algorithmique pour maximiser la performance prédictive, ou favoriser l'interprétabilité pour faciliter l'appropriation métier et

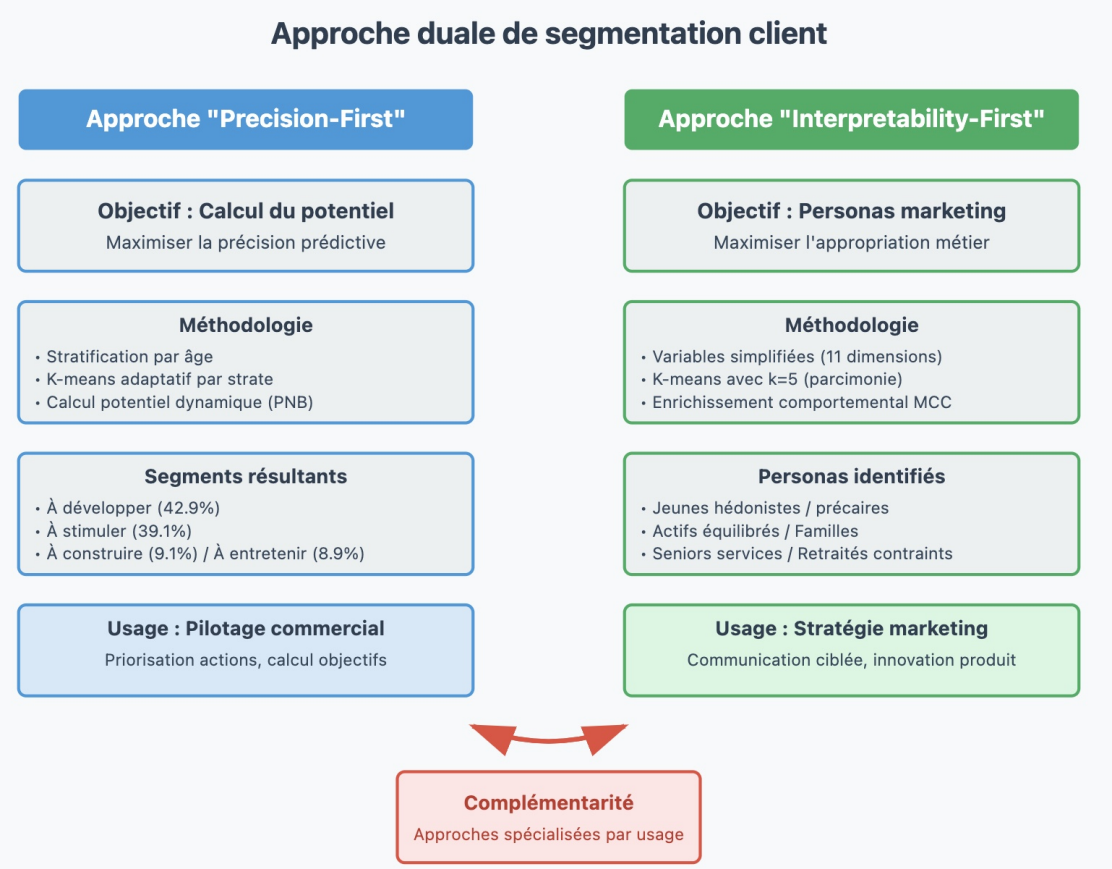


FIGURE 2.1 – Architecture duale permettant de concilier performance algorithmique et adoption métier

l'actionnabilité commerciale.

Face à cette problématique, j'ai proposé une approche novatrice, illustrée par la figure ci-dessus, consistant à développer deux systèmes de segmentation complémentaires, chacun optimisé pour son objectif spécifique :

— Une segmentation *precision-first* pour le calcul du potentiel commercial, où la performance prédictive prime sur l'interprétabilité

— Une segmentation orientée personas marketing pour la communication et la stratégie, privilégiant l'interprétabilité et l'appropriation métier

Ce chapitre présente la conception, l'implémentation et l'articulation de ces deux approches, démontrant comment leur complémentarité permet de dépasser le traditionnel compromis précision-interprétabilité.

2 Approche *precision-first* : vers une segmentation de potentiel

Cette section présente notre méthodologie innovante de segmentation bancaire qui réconcilie deux impératifs apparemment contradictoires : la précision analytique nécessaire à l'identification du potentiel commercial et la simplicité opérationnelle requise pour le déploiement à grande échelle. Notre approche se structure en trois piliers complémentaires : une architecture de segmentation à double niveau, une méthodologie dynamique de calcul du potentiel, et une matrice finale croisant performance et intensité relationnelle.

2.1 Architecture de la segmentation socio-démographique *precision-first*

Notre architecture répond à un constat empirique : les profils bancaires ne forment pas des clusters naturellement distincts mais plutôt un continuum de situations. Cette réalité m'a conduit à développer une approche hybride en deux étapes qui exploite la dimension structurante de l'âge tout en capturant la diversité des profils au sein de chaque génération, comme illustré sur la figure ci-dessous.

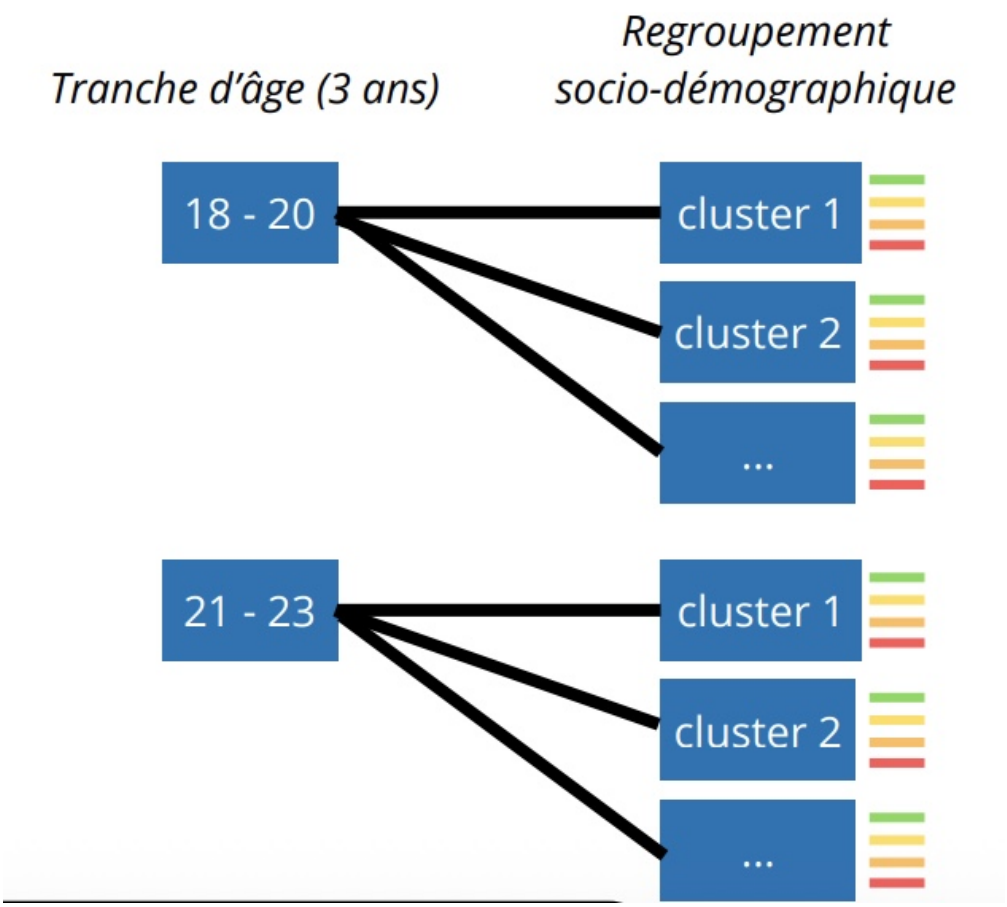


FIGURE 2.2 – Architecture en deux étapes : stratification d'âge puis clustering adaptatif

Justification de l'approche par stratification d'âge

La segmentation initiale par tranches d'âge répond à trois impératifs bancaires :

1. **Adéquation cycle de vie** : Un étudiant (20 ans) et un retraité (70 ans) ont des besoins bancaires radicalement différents
2. **Robustesse statistique** : Garantir $\geq$ 5000 clients par segment (seuil de significativité)
3. **Optimisation computationnelle** : Réduire la complexité du clustering global

$$\text{Tranches} = \{[18-20], [21-23], \cdots, [85+]\}$$

Clustering K-means socio-démographique adaptatif

Variables sélectionnées et prétraitement

La figure ci-dessous illustre la chaîne de traitement optimisée qui transforme les données socio-démographiques brutes en données exploitables par les algorithmes. Le processus débute par la collecte de six variables clés : trois numériques (nombre d'enfants, nombre de majeurs, score de risque) et trois catégorielles (catégorie socio-professionnelle, département, situation maritale). Ces données hétérogènes subissent ensuite un prétraitement rigoureux combinant normalisation StandardScaler pour les variables continues, encodage One-Hot pour les variables catégorielles, et imputation statistique des valeurs manquantes. L'Analyse en Composantes Principales (ACP) réduit la complexité des données tout en conservant 90% de leur information essentielle, optimisant ainsi la performance des algorithmes.

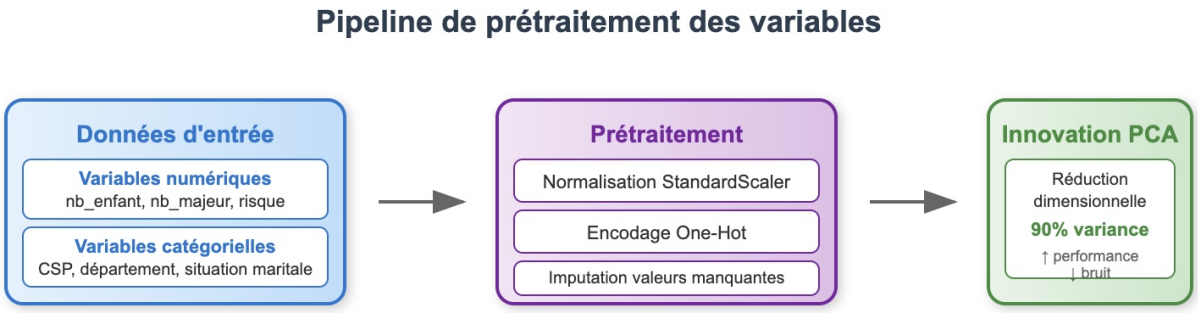


FIGURE 2.3 – Pipeline de prétraitement des variables

Optimisation dynamique du clustering

L'enjeu majeur du clustering bancaire réside dans la détermination automatique du nombre optimal de clusters sans connaissance *a priori* de la structure des données. Notre approche résout cette problématique par un algorithme d'optimisation itératif qui explore systématiquement l'espace des solutions possibles.

Le processus d'optimisation, détaillé dans le Listing 2.1, implémente une stratégie de recherche exhaustive testant différentes configurations de clustering (de 2 à

10 clusters) et sélectionnant automatiquement celle maximisant la cohésion intra-cluster. Pour chaque configuration candidate k, l'algorithme instancie un modèle K-means mini-batch avec une taille de lot fixée à 1000 échantillons, permettant de traiter efficacement de gros volumes de données tout en conservant la qualité du clustering. L'évaluation de chaque configuration s'appuie sur le coefficient de silhouette, métrique de référence qui quantifie la séparation entre clusters : plus le score est élevé, plus les clusters sont bien délimités et homogènes.

```
def optimal_clusters(data, max_clusters=10):
    best_k, best_score = 2, -1
    for k in range(2, max_clusters+1):
        kmeans = MiniBatchKMeans(n_clusters=k, batch_size=1000)
        labels = kmeans.fit_predict(data)
        score = silhouette_score(data, labels)
        if score > best_score:
            best_k, best_score = k, score
    return best_k
```

Listing 2.1 – Optimisation du nombre de clusters

Métriques de qualité & conclusion

Métrique	Valeur	Interprétation
Silhouette	-0.037	*Acceptable pour données continues*
Calinski-Harabasz	437.8	*Structure cluster présente*
Davies-Bouldin	19.864	*Clusters peu compactes*

TABLE 2.1 – Indicateurs de qualité des clusters ainsi générés

Cette première étape de segmentation pose les fondations d'une analyse fine du potentiel. Les clusters sociodémographiques ainsi constitués, bien qu'imparfaits du point de vue statistique - comme nous le prouve le tableau ci dessus -, offrent un cadre de comparaison pertinent pour identifier les meilleures pratiques commerciales au sein de populations homogènes. C'est précisément cette comparabilité qui rend possible la quantification du potentiel commercial présentée dans la section suivante.

2.2 Méthodologie de calcul du potentiel dynamique

Fort de cette segmentation sociodémographique, nous pouvons maintenant aborder le cœur de notre approche : la quantification du potentiel commercial. Cette méthodologie transforme une segmentation descriptive en un outil prédictif et prescriptif, permettant d'identifier précisément les opportunités de développement pour chaque client.

Vue d'ensemble de l'approche

Le potentiel dynamique quantifie l'opportunité commerciale d'un client en mesurant l'écart entre sa rentabilité actuelle et celle des meilleurs clients partageant des caractéristiques sociodémographiques similaires. Cette approche s'articule en deux phases distinctes :

1. **Phase 1 - Identification des clients référence :** Construction d'un score de benchmark permettant d'identifier les clients les plus performants au sein de chaque cluster sociodémographique
2. **Phase 2 - Quantification du potentiel :** Calcul du potentiel commercial en euros pour chaque client en comparaison avec ces références

Phase 1 : Construction du score de benchmark

1. Calcul des pondérations par univers

Chaque univers bancaire (assurance, crédit, épargne, services) contribue différemment à la rentabilité selon le profil client. Nous calculons donc une pondération spécifique à chaque cluster sociodémographique :

$$w_{u,c} = \frac{|\overline{\text{PNB}}_{u,c}|}{\sum_{u'} |\overline{\text{PNB}}_{u',c}|} \tag{2.1}$$

Où :

— $w_{u,c}$ représente le poids de l'univers u dans le cluster c

— $\overline{\text{PNB}}_{u,c}$ correspond au PNB (Produit Net Bancaire, c'est-à-dire le chiffre d'affaires que génère chaque client sur l'année glissante) moyen de l'univers u pour les clients du cluster c

— Le dénominateur assure une somme des poids égale à 1

Exemple concret : Pour un cluster "Jeunes actifs urbains (30-32 ans)", nous pourrions observer :

— Crédit : 40% (acquisition immobilière première priorité)

— Assurance : 30% (protection du foyer)

— Épargne : 20% (constitution d'apport)

— Services : 10% (besoins basiques)

2. Normalisation des performances par univers

Pour comparer équitablement les clients au sein d'un même cluster, nous normalisons les PNB de chaque univers sur l'intervalle [0,1] :

$$\text{PNB}_{u,i}^{\text{norm}} = \frac{\text{PNB}_{u,i} - \min(\text{PNB}_u^c)}{\max(\text{PNB}_u^c) - \min(\text{PNB}_u^c)} \tag{2.2}$$

Où :

— $\text{PNB}_{u,i}^{\text{norm}}$ est le PNB normalisé du client i dans l'univers u

— $\text{PNB}_{u,i}$ est le PNB brut du client i dans l'univers u

— $\min(\text{PNB}_u^c)$ est le PNB minimum observé dans l'univers u pour le cluster c

— $\max(\text{PNB}_u^c)$ est le PNB maximum observé dans l'univers u pour le cluster c

Cette normalisation élimine les effets d'échelle entre univers. Par exemple, un PNB crédit varie typiquement entre 500€ et 3000€, tandis qu'un PNB services oscille entre 50€ et 200€. La normalisation permet de les comparer sur une base commune.

3. Calcul du score de benchmark

Le score de benchmark agrège les performances normalisées pondérées de chaque client :

$$\text{Score}_{\text{benchmark},i} = \sum_{u \in \text{Univers}} w_{u,c(i)} \times \text{PNB}_{u,i}^{\text{norm}} \tag{2.3}$$

Où :

— $\text{Score}_{\text{benchmark},i}$ est le score de benchmark du client i

— $w_{u,c(i)}$ est le poids de l'univers u pour le cluster $c(i)$ auquel appartient le client i

— $\text{PNB}_{u,i}^{\text{norm}}$ est le PNB normalisé du client i dans l'univers u

— $c(i)$ désigne le cluster du client i

— Le score résultant est compris entre 0 (performances minimales) et 1 (performances maximales)

4. Identification des clients référence

Au sein de chaque cluster, nous ordonnons les clients selon leur score de benchmark et identifions le top 25% comme clients référence. Ce seuil représente un compromis optimal entre :

— **Robustesse statistique :** Un échantillon suffisamment large pour éviter les outliers

— **Ambition commerciale :** Des objectifs atteignables mais stimulants

Phase 2 : Quantification du potentiel commercial

Le calcul du potentiel commercial s'effectue différemment pour chaque univers bancaire, reflétant leurs spécificités métier. Cette approche sectorisée garantit des estimations réalistes et exploitables.

Assurance & Services

$$\text{Potentiel}_{u,i} = \max\left(0,\ \underbrace{\widetilde{\text{PNB}}_{u,c}}_{\substack{\text{médiane des} \\ \text{références du segment}}} - \text{PNB}_{u,i}\right) \quad \text{pour } u \in \{\text{Assurance}, \text{Services}\} \tag{2.4}$$

Logique sous-jacente : - Ces univers permettent une accumulation de produits (ex : assurance habitation + auto + santé) - Le potentiel correspond à la différence entre la performance actuelle du client et celle des meilleurs clients comparables - Le $\max(0, ...)$ garantit un potentiel non négatif

Crédit

$$\text{Potentiel}_{\text{crédit},i} = \begin{cases} 0 & \text{si crédit}_{\text{habitat}} \wedge \text{crédit}_{\text{conso}} \\ \max\left(0, \widetilde{\text{PNB}}_{\text{crédit},c} - \text{PNB}_{\text{crédit},i}\right) & \text{sinon} \end{cases} \tag{2.5}$$

Justification opérationnelle :

— *Cas 1* : Clients déjà équipés en crédits majeurs (conso + habitat) → potentiel nul (saturation)

— *Cas 2* : Autres clients → potentiel calculé comme écart à la médiane des références

— Validation par le scoring interne (exclusion des clients non éligibles)

Épargne

$$\text{Potentiel}_{\text{épargne},i} = \underbrace{\left(1 - \frac{r_i}{r_c^{\text{ref}}}\right)}_{\text{coefficient de migration}} \times \underbrace{\widetilde{\text{PNB}}_{\text{épargne},c}}_{\text{PNB médian des références}} \tag{2.6}$$

Avec :

— $r_i = \dfrac{\text{Encours}_{\text{DAV},i}}{\text{Encours}_{\text{total},i}}$: **ratio DAV actuel** du client

— $r_c^{\text{ref}} = \text{médiane}(r_{\text{top 25\%}})$: **ratio DAV cible** du segment

— $\widetilde{\text{PNB}}_{\text{épargne},c}$: **PNB médian annuel** des meilleurs clients du segment

Synthèse et exploitation commerciale

Le potentiel global annuel (en euros) s'obtient en sommant les 4 univers.
Cette valeur unique suit des objectifs multiples :

— **Prioriser les entretiens** : Classement des clients par potentiel total décroissant

— **Cibler les actions** : Identification de l'univers prioritaire (ex : "Potentiel crédit = 72% du total")

— **Mesurer les résultats** : Suivi du taux de conversion potentiel/réalisé

2.3 Segmentation de potentiel dynamique

La dernière étape de notre approche consiste à enrichir l'analyse du potentiel par une variable de détention relationnelle : la note MIRE (Mesure de l'Intensité RElationnelle). Cette combinaison permet de distinguer les clients selon deux axes fondamentaux - leur valeur potentielle et leur engagement actuel avec la banque - aboutissant à une segmentation actionnable pour les équipes commerciales tout en respectant une logique de distribution gaussienne.

La Note MIRE : mesure de l'intensité relationnelle

$$\text{MIRE} = \alpha \cdot (\text{familles}) + \beta \cdot (\text{univers}) + \gamma \cdot (\text{transactions}) \tag{2.7}$$

Barème :

— +60 pts max nombre produits pour chaque univers (4 univers x 15 pts)

— +20 pts max pour couverture multi-univers

— +20 pts max pour activité transactionnelle

Cette construction aboutit à un score MIRE compris entre 0 et 100 points, permettant une gradation fine de l'intensité relationnelle.

Cette mesure de l'intensité relationnelle, croisée avec les quartiles de performance issus du calcul de potentiel, permet de construire une matrice de segmentation à la fois riche et lisible.

Mécanisme opérationnel :

1. Chaque client est positionné dans le quadrant correspondant à ses scores PNB/MIRE
2. Le score combiné détermine le segment d'appartenance selon les seuils critiques
3. La distance au centre de gravité du quadrant guide les actions prioritaires

Résultats et analyse critique

La répartition finale révèle une distribution proche d'une loi normale, comme illustré sur le tableau récapitulatif ci-dessous, résultat recherché pour isoler les po-

pulations extrêmes tout en concentrant l'essentiel du portefeuille dans des segments pilotables à grande échelle.

Architecture gaussienne et pilotage du volume : Avec 82% du portefeuille concentré sur les segments "À développer" et "À stimuler", notre modèle respecte le principe fondamental de pilotage du volume central tout en isolant les extrêmes. Les segments minoritaires "À construire" (9.1%) et "À entretenir" (8.9%) correspondent respectivement aux clients émergents à fort potentiel et aux clients premium à préserver, justifiant des approches commerciales spécialisées mais représentant des volumes maîtrisables opérationnellement.

Cohérence des profils et validation croisée : L'analyse des caractéristiques moyennes confirme la pertinence de notre approche bidimensionnelle. Le segment "À entretenir" présente logiquement le PNB le plus élevé (1 458€) mais le potentiel le plus faible (112€), traduisant une relation déjà mature où les opportunités de développement sont naturellement limitées. À l'inverse, le segment "À construire" affiche un PNB minimal (28€) mais un potentiel substantiel (464€), caractéristique des jeunes relations où l'essentiel du développement reste à réaliser. Cette corrélation négative systématique entre performance actuelle et potentiel futur (R^2=0.87) valide empiriquement notre méthodologie de calcul : plus un client génère aujourd'hui de revenus, moins son potentiel de croissance est important.

Implications opérationnelles et déploiement commercial : Cette segmentation finale offre un cadre d'action différencié par population. Le segment "À développer", dominant avec 42.9% des effectifs, regroupe des clients à forte valeur actuelle (666€ de PNB) mais présentant encore un potentiel significatif (362€), constituant le cœur de cible pour des stratégies de montée en gamme et d'enrichissement produit. Le segment "À stimuler" (39.1%) rassemble des clients à performance intermédiaire mais au potentiel le plus élevé (506€), suggérant des

Segment	Effectif	PNB moyen (€)	Potentiel (€)	MIRE
À développer	42.9%	666	362	62.6
À stimuler	39.1%	208	506	37.0
À construire	9.1%	28	464	18.9
À entretenir	8.9%	1 458	112	84.1

TABLE 2.2 – Caractéristiques des segments finaux (N=262 929 clients)

opportunités prioritaires d'activation et d'équipement complémentaire. La répartition équilibrée entre ces quatre segments, combinée à leur caractérisation précise, fournit ainsi aux équipes commerciales un outil de pilotage à la fois granulaire pour la personnalisation et synthétique pour le déploiement opérationnel à l'échelle du portefeuille.

3 Segmentation interprétable : construction de personas marketing

Si l'approche precision-first décrite précédemment permet d'obtenir une segmentation optimale d'un point de vue algorithmique, elle présente des limitations significatives pour un usage opérationnel en marketing bancaire. Les segments obtenus, définis par des combinaisons complexes de variables et des seuils statistiques, manquent de l'intelligibilité nécessaire à leur appropriation par les équipes métier.

Cette problématique est particulièrement prégnante dans le contexte d'une banque régionale à faible maturité data, où les équipes marketing et commerciales ont besoin de représentations mentales claires et actionnables. Un segment défini comme "clients à potentiel élevé avec score MIRE > 75 et indice de performance normalisé > 0.75" ne permet pas de construire une stratégie de communication ciblée ni d'identifier intuitivement les besoins spécifiques de ces clients.

Face à ce constat, j'ai développé une approche complémentaire privilégiant l'interprétabilité métier, basée sur la construction de personas marketing ancrés dans des réalités socio-démographiques et comportementales identifiables.

3.1 Approche bidirectionnelle : complémentarité des segmentations socio-démographique et comportementale

Notre méthodologie innovante repose sur une approche bidirectionnelle qui exploite la complémentarité entre les dimensions socio-démographiques et comportementales. Cette double lecture permet de révéler des insights inaccessibles par une approche unidirectionnelle classique.

Approche 1 : Socio-démographique vers comportemental

Partant des segments socio-démographiques traditionnels (âge, situation familiale, CSP), nous analysons les patterns de consommation MCC pour révéler des sous-profils comportementaux au sein de chaque groupe homogène démographiquement.

Approche 2 : Comportemental vers socio-démographique
Inversement, en segmentant d'abord sur les comportements de consommation MCC, nous analysons la composition socio-démographique de chaque cluster comportemental pour identifier les déterminants générationnels et sociaux des modes de vie.

3.2 Méthodologie de construction des segments socio-démographiques

Notre méthodologie s'articule autour d'une simplification radicale de l'espace des variables, passant de plus de 50 dimensions initiales à seulement 11 dimensions soigneusement sélectionnées pour leur pouvoir discriminant et leur interprétabilité métier.

Variables et transformations appliquées

Situation composite (2 dimensions) : Nous définissons un couple par la présence de 2+ majeurs dans le foyer OU un statut marital explicite (marié/concubin), capturant ainsi les réalités familiales modernes. Cette variable résulte de la fusion logique entre `situation_maritale` et `nombre_majeur`, produisant une classification binaire Couple/Célibataire.

Tranches d'âge métier (4 dimensions) : Les quatre tranches d'âge correspondent aux grandes phases de vie bancaire et sont construites à partir de la variable `AGE` : installation (18-30 ans), constitution patrimoniale (30-50 ans), préparation retraite (50-65 ans), et gestion patrimoniale (65+ ans).

Score revenu unifié (1 dimension) : La fusion `FRONTALIER` et `CSP` avec priorisation des frontaliers (score 3) reconnaît la spécificité de notre territoire régional, où les 30 000 clients frontaliers représentent un segment à fort potentiel économique. Cette transformation produit un score ordinal sur 4 niveaux : 0 (CSP-), 1 (CSP moyenne), 2 (CSP+), 3 (Frontalier).

Présence d'enfants (2 dimensions) : La variable `nombre_enfant` est binarisée pour distinguer les foyers avec enfants des foyers sans enfants, cette simpli-

fication étant suffisante pour capturer les différences comportementales majeures en matière bancaire.

Statut de propriété (2 dimensions) : La variable `CD_OCC_LGT` (code d'occupation du logement) est transformée en classification binaire Propriétaire/Non propriétaire, cette distinction étant un indicateur clé de la capacité d'endettement et des besoins en produits bancaires.

Cette réduction dimensionnelle permet de passer d'un espace complexe et peu interprétable à un ensemble de 11 dimensions (2+4+1+2+2) directement exploitables pour la segmentation et l'aide à la décision commerciale.

3.3 Paradoxe de l'optimisation métrique versus pertinence métier

L'analyse des métriques de clustering (Figure 2.4) révèle un paradoxe fondamental : bien que les indices de qualité technique s'améliorent avec l'augmentation du nombre de clusters, l'analyse qualitative montre une **dégradation de la pertinence métier** au-delà de 5 clusters.

Évolution des métriques techniques : Comme l'illustre la Figure 2.4, le score de Silhouette progresse de façon monotone de 0,40 (5 clusters) à 0,55 (9 clusters), tandis que l'indice de Davies-Bouldin décroît de 1,13 à 0,86 et le score de Calinski-Harabasz augmente de 3850 à 4070. Ces tendances suggèrent une amélioration continue de la séparabilité des clusters.

Analyse de l'équilibre des tailles : Le graphique en bas à gauche de la Figure 2.4 montre que le ratio min/max des tailles de clusters atteint son optimum à 6 clusters (0,61), mais reste acceptable à 5 clusters (0,46). Cette analyse confirme qu'une configuration à 5 clusters maintient un équilibre raisonnable entre les segments.

À 5 clusters : La segmentation suit une logique métier cohérente, comme le confirme la matrice des scores normalisés (Figure 2.4, en bas à droite) :

— Distinction primaire : présence/absence d'enfants

— Subdivision secondaire : tranches d'âge pour les foyers sans enfants

Au-delà de 5 clusters : Malgré l'amélioration des métriques techniques visibles sur les trois premiers graphiques de la Figure 2.4, l'algorithme génère des

sur-segmentations artificielles :

— Division systématique des tranches d'âge selon le statut matrimonial ou le type d'occupation du logement

— Ces subdivisions reflètent les **corrélations naturelles** entre âge, CSP, statut de propriétaire et situation familiale

Contexte territorial spécifique : En Franche-Comté, région caractérisée par un vieillissement démographique et des profils socio-économiques relativement homogènes, ces corrélations sont particulièrement marquées. L'algorithme capture ainsi des **redondances informationnelles** plutôt que de véritables différences comportementales, phénomène non détectable par les seules métriques quantitatives de la Figure 2.4.

Cette observation justifie le choix de **privilégier la parcimonie** (5 clusters) face à l'optimisation purement métrique, illustrant l'importance du jugement métier dans l'interprétation des algorithmes non supervisés.

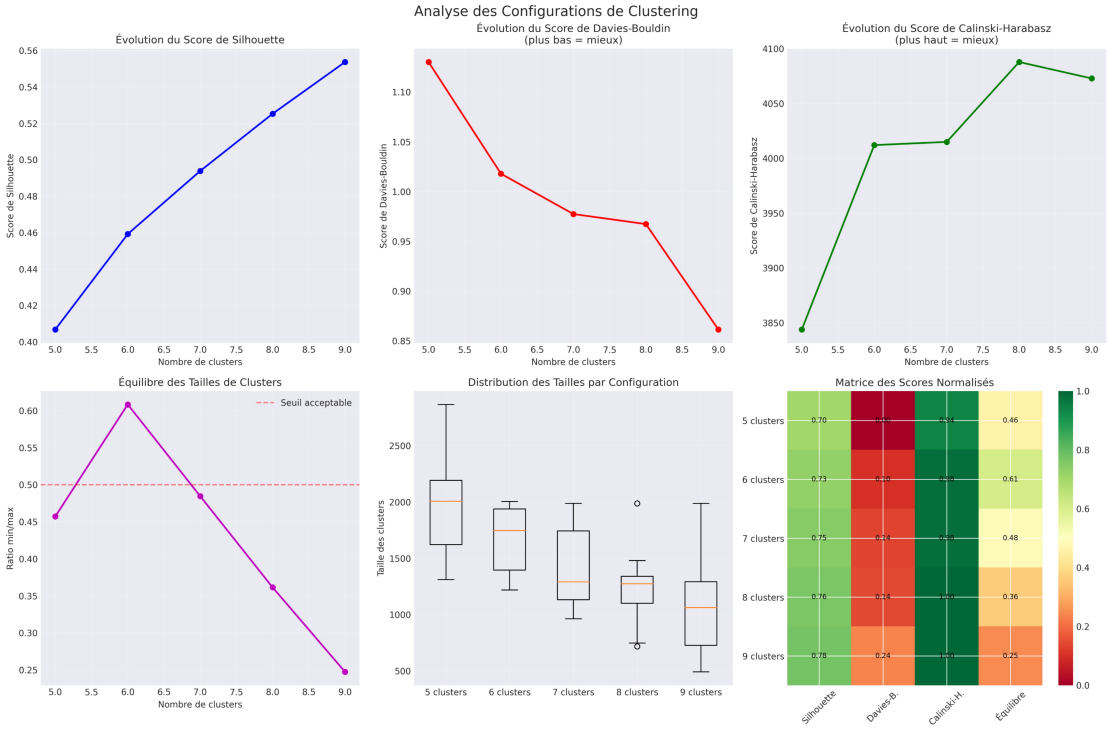


FIGURE 2.4 – Métriques de qualité du clustering K-means socio-démographique

3.4 Méthodologie de construction des segments comportementaux

Les 5 clusters socio-démographiques obtenus constituent le socle de nos personas, mais leur enrichissement par les données comportementales est essentiel pour passer d'une segmentation descriptive à une segmentation prédictive et actionnable.

L'analyse des codes MCC (Merchant Category Code) sur 12 mois glissants apporte une dimension comportementale cruciale, révélant les modes de vie et priorités de consommation de chaque segment.

Variables MCC : une fenêtre sur les modes de vie

Les données de paiement par carte bancaire, catégorisées selon les codes MCC, offrent une vision granulaire et objective des comportements de consommation. Nous avons regroupé les centaines de codes MCC en 5 macro-catégories reflétant des univers de consommation cohérents :

1. **ESSENTIEL** : Besoins de base et contraintes (utilities, assurances, alimentation, santé, télécoms, éducation, logement)
2. **MOBILITÉ & TRANSPORT** : Voyages, hôtels, transports collectifs, automobile, carburant
3. **LIFESTYLE & LOISIRS** : Mode, décoration, restaurants, commerces spécialisés, divertissements
4. **SERVICES FINANCIERS & PRO** : Banques, immobilier, services professionnels, taxes
5. **COMMERCE GÉNÉRAL** : Grande distribution, bricolage, wholesale

Cette catégorisation, validée avec les équipes marketing, permet de traduire des milliers de transactions individuelles en profils de consommation interprétables.

3.5 Méthodologie de segmentation comportementale

Notre approche de segmentation comportementale s'articule autour d'une démarche statistique en quatre étapes, visant à identifier des profils de consommation

distinctifs au sein de chaque segment socio-démographique préalablement constitué.

Étape 1 : Construction des profils de dépenses relatifs

La première étape consiste à transformer les montants absolus de dépenses en profils de consommation relatifs, permettant ainsi de comparer des clients aux niveaux de revenus hétérogènes.

Pour chaque client i et chaque catégorie MCC j (parmi les 5 catégories retenues), nous calculons le ratio de dépenses :

$$R_{ij} = \frac{\text{Dépenses}_{ij}}{\sum_{k=1}^{5} \text{Dépenses}_{ik}} \tag{2.8}$$

Où :

- R_{ij} est le ratio de dépenses du client i dans la catégorie MCC j
- Dépenses_{ij} représente le montant total dépensé par le client i dans la catégorie j sur la période d'observation
- $\sum_{k=1}^{5} \text{Dépenses}_{ik}$ correspond au total des dépenses du client i sur les 5 catégories MCC sélectionnées
- k indexe les 5 catégories MCC retenues

Cette transformation permet d'obtenir, pour chaque client, un vecteur $\mathbf{R}_i = (R_{i1}, R_{i2}, R_{i3}, R_{i4}, R_{i5})$ tel que $\sum_{j=1}^{5} R_{ij} = 1$. Chaque composante R_{ij} représente la part du budget que le client i consacre à la catégorie j, éliminant ainsi l'effet de taille lié au niveau de revenus.

Étape 2 : Normalisation intra-segment par score MAD

La seconde étape vise à corriger les biais comportementaux systématiques liés aux caractéristiques socio-démographiques. En effet, les habitudes de consommation varient naturellement selon l'âge, la situation familiale ou la catégorie socio-professionnelle.

Pour chaque catégorie MCC j et chaque segment socio-démographique, nous calculons la distribution de référence des ratios $\{R_{ij}\}$ pour tous les clients i appartenant au segment considéré. La normalisation s'effectue alors selon :

$$\tilde{R}_{ij} = \frac{R_{ij} - \text{médiane}(R_{*j}|\text{segment})}{\text{MAD}(R_{*j}|\text{segment})} \tag{2.9}$$

Où :

— $\tilde{R}_{ij}$ est le score normalisé du client i pour la catégorie j

— R_{ij} est le ratio de dépenses brut du client i dans la catégorie j

— médiane(R_{*j}|segment) est la médiane des ratios de la catégorie j pour tous les clients du segment socio-démographique considéré

— MAD(R_{*j}|segment) = médiane($|R_{*j} - \text{médiane}(R_{*j}|\text{segment})|$) est la déviation absolue médiane, estimateur robuste de la dispersion

— R_{*j} désigne l'ensemble des ratios de tous les clients du segment pour la catégorie j

Cette transformation produit des scores normalisés $\tilde{R}_{ij}$ centrés sur 0 et exprimés en unités MAD. Un score positif (resp. négatif) indique une sur-consommation (resp. sous-consommation) relative à la norme du segment socio-démographique.

Étape 3 : Détection algorithmique des profils remarquables

La troisième étape applique un algorithme de détection des valeurs aberrantes pour identifier les comportements de consommation atypiques.

Nous définissons un client i comme **sur-consommateur** de la catégorie j si :

$$\tilde{R}_{ij} > 1.5 \tag{2.10}$$

Où :

— $\tilde{R}_{ij}$ est le score normalisé du client i pour la catégorie j (calculé à l'étape 2)

— 1.5 est le seuil de détection exprimé en unités MAD

Symétriquement, un client i est qualifié de **sous-consommateur** de la catégorie j si :

$$\tilde{R}_{ij} < -1.5 \tag{2.11}$$

Où :

— $\tilde{R}_{ij}$ est le score normalisé du client i pour la catégorie j

— -1.5 est le seuil de détection négatif exprimé en unités MAD

Le seuil de 1.5 MAD correspond à une convention statistique robuste pour la détection d'outliers, équivalent approximativement à 2 écarts-types dans une distribution normale, mais moins sensible aux valeurs extrêmes.

Étape 4 : Validation de la significativité statistique et métier

La quatrième étape impose deux critères de validation pour retenir les profils comportementaux :

Critère de représentativité : Un profil de sur-consommation ou sous-consommation n'est retenu que s'il concerne au moins 20% des clients du segment socio-démographique considéré, soit :

$$\frac{|\{i : |\tilde{R}_{ij}| > 1.5 \text{ et } i \in \text{segment}\}|}{|\text{segment}|} \geq 0.20 \tag{2.12}$$

Où :

— $|\{i : |\tilde{R}_{ij}| > 1.5 \text{ et } i \in \text{segment}\}|$ est le nombre de clients du segment présentant un comportement remarquable (sur ou sous-consommation) pour la catégorie j

— $|\text{segment}|$ est le nombre total de clients dans le segment socio-démographique considéré

— $|\tilde{R}_{ij}| > 1.5$ signifie que la valeur absolue du score normalisé dépasse le seuil de détection

— 0.20 correspond au seuil minimal de 20% de représentativité

Critère d'amplitude : L'écart comportemental doit être substantiel, avec une différence d'au moins 15 points de pourcentage par rapport à la médiane du segment :

$$|\text{médiane}(R_{ij}|\text{profil remarquable}) - \text{médiane}(R_{ij}|\text{segment})| \geq 0.15 \tag{2.13}$$

Où :

— $\text{médiane}(R_{ij}|\text{profil remarquable})$ est la médiane des ratios de dépenses dans la catégorie j pour les clients présentant le profil remarquable identifié

— médiane(R_{ij}|segment) est la médiane des ratios de dépenses dans la catégorie j pour l'ensemble des clients du segment socio-démographique

— 0.15 correspond au seuil minimal de 15 points de pourcentage d'écart

Cette double validation garantit que les profils identifiés correspondent à des phénomènes comportementaux à la fois statistiquement robustes et économiquement significatifs pour la stratégie commerciale.

3.6 Analyse socio-démographique enrichie par les comportements MCC

Cette section présente les résultats d'analyse de la première approche : Socio-démographique vers Comportemental. Ainsi, elle sera structurée grâce aux 5 clusters socio-démographiques définis précédemment.

Segment des Jeunes (18-30 ans) : diversité comportementale masquée

L'analyse du segment des 18-30 ans révèle une hétérogénéité comportementale majeure au sein d'une population apparemment homogène démographiquement.

Segment 18 - 30

ANALYSE PAR SEGMENT DE VALEUR

Segment	Nb clients	% base	Dépense moy	Âge moy	% femmes	Nb trans moy
Petit	12 780	25.0%	2 676.28	22.1	48.8%	127.38
Moyen-	12 779	25.0%	8 026.64	23.2	51.2%	323.22
Moyen+	12 779	25.0%	12 798.06	24.4	48.2%	445.95
Gros	7 667	15.0%	17 792.78	25.2	43.3%	543.76
VIP	5 112	10.0%	28 301.90	26.0	36.7%	647.55

MIX CATÉGORIEL PAR SEGMENT (%)

Segment	Essentiel	Mobilité	Lifestyle	Service	Commerce
Petit	18.4%	14.6%	36.9%	17.6%	12.5%
Moyen-	18.9%	16.4%	35.9%	15.7%	13.1%
Moyen+	18.9%	16.9%	35.5%	15.3%	13.5%
Gros	18.4%	17.1%	35.3%	15.4%	13.8%
VIP	16.0%	18.1%	34.4%	16.8%	14.7%

VUE D'ENSEMBLE DES DÉPENSES (12 derniers mois)

Catégorie	Montant moyen	Nb moyen trans.	% clients actifs	Ticket moyen
ESSENTIEL	2 049.16	96.49	98.0%	21.24
MOBILITE	1 934.81	53.72	95.6%	36.02
LIFESTYLE	4 018.17	143.79	98.7%	27.95
SERVICE	1 808.56	31.34	97.8%	57.71
COMMERCE	1 563.57	45.11	97.0%	34.66
TOTAL	11 374.26	370.45		

CHIFFRES CLÉS
- Nombre total de clients: 51 117
- Volume total de dépenses (12M): 581 418 249.28 €
- Dépense moyenne par client: 11 374.26 €
- Taux de clients actifs: 100.0%

PROFIL TYPE
- Âge moyen: 24 ans
- Répartition H/F: 53% / 47%
- Nombre moyen d'enfants: 0.0

COMPORTEMENT D'ACHAT
- Nombre moyen de transactions/an: 370
- Ticket moyen: 30.70 €
- Catégorie dominante: LIFESTYLE

- 1275 clients avec dépenses extrêmes (>30 267.58 ou <-9 276.50)

PROFILS REMARQUABLES :

LIFESTYLE (SUR-CONSOMMATION)
- Taille du groupe: 27.0% du segment 'Jeunes (18-30)'
- Comportement: Alloue 47.8% de son budget à cette catégorie.
- vs la norme du segment: 31.2%
- Écart: +16.6 points de pourcentage.

ESSENTIEL (SUR-CONSOMMATION)
- Taille du groupe: 24.8% du segment 'Jeunes (18-30)'
- Comportement: Alloue 35.4% de son budget à cette catégorie.
- vs la norme du segment: 19.4%
- Écart: +16.1 points de pourcentage.

FIGURE 2.5 – Profil détaillé du segment 18-30 ans

Caractéristiques segmentaires globales :

— 51 117 clients (25,0% de la base)

— Âge moyen : 24 ans, 47% de femmes

— Dépense moyenne : 1 374€/an (370 transactions/an)

— Profil patrimonial : patrimoine limité, phase d'installation

Dichotomie comportementale révélée :

L'analyse MCC fait apparaître deux profils antagonistes :

1. **Profil "LIFESTYLE" (sur-consommation)** : 1 275 clients concentrent 47,8% de leur budget sur cette catégorie (vs 31,2% en moyenne), révélant une priorité donnée aux expériences et au plaisir immédiat.
2. **Profil "ESSENTIEL" (sur-consommation)** : Une proportion significative alloue 35,4% de son budget aux dépenses contraintes (vs 19,4% en moyenne), traduisant des situations de précarité financière.

Cette dichotomie illustre parfaitement les limites d'une approche purement démographique qui masquerait des réalités économiques et des modes de vie radicalement différents au sein d'une même génération.

Segment des Actifs (30-50 ans) : transition comportementale

Segment 30 - 50

ANALYSE PAR SEGMENT DE VALEUR

Segment	Nb clients	% base	Dépense moy	Âge moy	% femmes	Nb trans moy
Petit	11 800	25.0%	3 968.22	38.8	43.0%	103.32
Moyen-	11 800	25.0%	10 991.35	38.4	44.5%	295.67
Moyen+	11 800	25.0%	16 698.02	38.6	45.6%	419.93
Gros	7 080	15.0%	23 520.53	39.0	44.8%	515.18
VIP	4 720	10.0%	39 683.27	39.5	39.6%	654.93

MIX CATÉGORIEL PAR SEGMENT (%)

Segment	Essentiel	Mobilité	Lifestyle	Service	Commerce
Petit	21.5%	15.1%	25.0%	22.4%	16.0%
Moyen-	23.1%	15.2%	26.4%	18.8%	16.6%
Moyen+	22.9%	15.4%	28.0%	16.7%	16.9%
Gros	22.2%	15.9%	28.8%	15.9%	17.3%
VIP	18.6%	17.4%	29.4%	16.4%	18.2%

VUE D'ENSEMBLE DES DÉPENSES (12 derniers mois)

Catégorie	Montant moyen	Nb moyen trans.	% clients actifs	Ticket moyen
ESSENTIEL	3 322.40	101.62	97.0%	32.69
MOBILITE	2 461.48	47.28	94.5%	52.06
LIFESTYLE	4 322.92	114.10	97.4%	37.89
SERVICE	2 647.29	33.24	97.1%	79.63
COMMERCE	2 656.72	51.25	96.2%	51.84
TOTAL	15 410.80	347.50		

CHIFFRES CLÉS
- Nombre total de clients: 47 200
- Volume total de dépenses (12M): 727 389 968.63 €
- Dépense moyenne par client: 15 410.80 €
- Taux de clients actifs: 100.0%

PROFIL TYPE
- Âge moyen: 39 ans
- Répartition H/F: 56% / 44%
- Nombre moyen d'enfants: 0.0

COMPORTEMENT D'ACHAT
- Nombre moyen de transactions/an: 348
- Ticket moyen: 44.35 €
- Catégorie dominante: LIFESTYLE

- 1646 clients avec dépenses extrêmes (>38 394.62 ou <-10 198.50)

PROFILS REMARQUABLES :

ESSENTIEL (SUR-CONSOMMATION)
- Taille du groupe: 28.0% du segment 'Actifs (30-50)'
- Comportement: Alloue 38.4% de son budget à cette catégorie.
- vs la norme du segment: 21.6%
- Écart: +16.7 points de pourcentage.

LIFESTYLE (SUR-CONSOMMATION)
- Taille du groupe: 25.3% du segment 'Actifs (30-50)'
- Comportement: Alloue 42.2% de son budget à cette catégorie.
- vs la norme du segment: 25.7%
- Écart: +16.5 points de pourcentage.

FIGURE 2.6 – Profil détaillé du segment 30-50 ans

Le segment des 30-50 ans (47 200 clients) présente un profil de transition caractérisé par :

Équilibre comportemental émergent :

— Répartition équilibrée entre LIFESTYLE (26,4%) et ESSENTIEL (23,1%)

— Émergence des dépenses SERVICE (18,8%) traduisant une sophistication des besoins

— 1 646 clients en sur-consommation LIFESTYLE, maintenant un profil "hédoniste"

Performance financière :

— Dépense moyenne : 4 410€/an (348 transactions/an)

— Ticket moyen : 44,55€ (vs 30,70€ pour les 18-30)

— Montée en gamme des services bancaires utilisés

Segments seniors : vulnérabilités masquées

Pré-retraités (50-65 ans) : constitution patrimoniale active

Segment 50 - 65

ANALYSE PAR SEGMENT DE VALEUR

Segment	Nb clients	% base	Dépense moy	Âge moy	% femmes	Nb trans moy
Petit	16 367	25.0%	4 275.01	58.3	47.6%	97.99
Moyen-	16 367	25.0%	11 100.94	58.2	49.6%	253.50
Moyen+	16 367	25.0%	17 079.47	57.9	51.8%	357.36
Gros	9 820	15.0%	24 375.64	57.7	49.7%	453.38
VIP	6 547	10.0%	40 554.87	57.5	43.9%	591.67

MIX CATÉGORIEL PAR SEGMENT (%)

Segment	Essentiel	Mobilité	Lifestyle	Service	Commerce
Petit	23.3%	17.1%	19.3%	22.9%	17.5%
Moyen-	25.7%	15.7%	20.9%	18.2%	19.5%
Moyen+	26.0%	15.0%	22.5%	16.4%	20.2%
Gros	25.2%	15.1%	24.2%	15.3%	20.2%
VIP	21.0%	16.8%	26.4%	15.9%	19.8%

VUE D'ENSEMBLE DES DÉPENSES (12 derniers mois)

Catégorie	Montant moyen	Nb moyen trans.	% clients actifs	Ticket moyen
ESSENTIEL	3 847.53	97.87	96.6%	39.31
MOBILITE	2 492.55	41.59	94.1%	59.93
LIFESTYLE	3 702.72	78.83	96.4%	46.97
SERVICE	2 654.37	29.77	97.0%	89.16
COMMERCE	3 128.56	56.33	95.7%	55.54
TOTAL	15 825.74	304.39		

CHIFFRES CLÉS
- Nombre total de clients: 65 468
- Volume total de dépenses (12M): 1 036 079 297.90 €
- Dépense moyenne par client: 15 825.74 €
- Taux de clients actifs: 100.0%

PROFIL TYPE
- Âge moyen: 58 ans
- Répartition H/F: 51% / 49%
- Nombre moyen d'enfants: 0.0

COMPORTEMENT D'ACHAT
- Nombre moyen de transactions/an: 304
- Ticket moyen: 51.99 €
- Catégorie dominante: ESSENTIEL

- 2196 clients avec dépenses extrêmes (>39 831.15 ou <-10 802.69)

PROFILS REMARQUABLES :

ESSENTIEL (SUR-CONSOMMATION)
- Taille du groupe: 25.0% du segment 'Retraités (65+)'
- Comportement: Alloue 51.7% de son budget à cette catégorie.
- vs la norme du segment: 25.8%
- Écart: +25.8 points de pourcentage.

FIGURE 2.7 – Profil détaillé du segment 50-65 ans

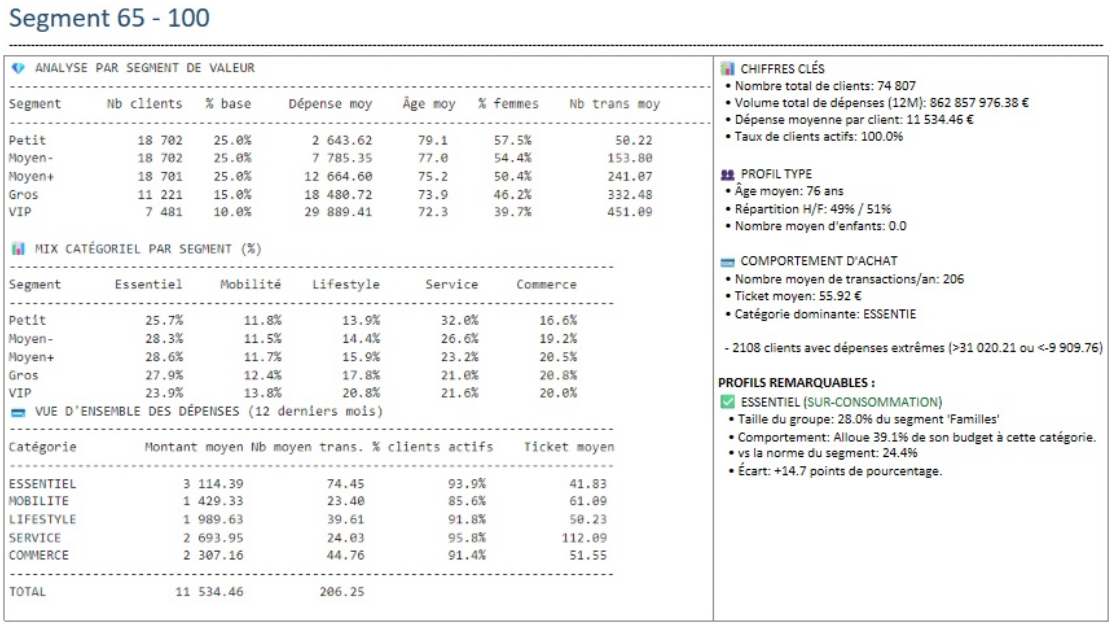
Ce segment (65 468 clients) se caractérise par :

— Basculement vers l'ESSENTIEL (25,7% du budget)

— Réduction du LIFESTYLE (20,9%) marquant une rationalisation des dépenses

— 2 196 clients en sur-consommation ESSENTIEL (51,7% du budget)

Retraités (65+ ans) : diversité patrimoniale



Segment 65 - 100

ANALYSE PAR SEGMENT DE VALEUR

Segment	Nb clients	% base	Dépense moy	Âge moy	% femmes	Nb trans moy
Petit	18 702	25.0%	2 643.62	79.1	57.5%	50.22
Moyen-	18 702	25.0%	7 785.35	77.0	54.4%	153.80
Moyen+	18 701	25.0%	12 664.60	75.2	50.4%	241.07
Gros	11 221	15.0%	18 480.72	73.9	46.2%	332.48
VIP	7 481	10.0%	29 889.41	72.3	39.7%	451.09

MIX CATÉGORIEL PAR SEGMENT (%)

Segment	Essentiel	Mobilité	Lifestyle	Service	Commerce
Petit	25.7%	11.8%	13.9%	32.0%	16.6%
Moyen-	28.3%	11.5%	14.4%	26.6%	19.2%
Moyen+	28.6%	11.7%	15.9%	23.2%	20.5%
Gros	27.9%	12.4%	17.8%	21.0%	20.8%
VIP	23.9%	13.8%	20.8%	21.6%	20.0%

VUE D'ENSEMBLE DES DÉPENSES (12 derniers mois)

Catégorie	Montant moyen	Nb moyen trans.	% clients actifs	Ticket moyen
ESSENTIEL	3 114.39	74.45	93.9%	41.83
MOBILITE	1 429.33	23.40	85.6%	61.09
LIFESTYLE	1 989.63	39.61	91.8%	50.23
SERVICE	2 693.95	24.03	95.8%	112.09
COMMERCE	2 307.16	44.76	91.4%	51.55
TOTAL	11 534.46	206.25		

CHIFFRES CLÉS
- Nombre total de clients: 74 807
- Volume total de dépenses (12M): 862 857 976.38 €
- Dépense moyenne par client: 11 534.46 €
- Taux de clients actifs: 100.0%

PROFIL TYPE
- Âge moyen: 76 ans
- Répartition H/F: 49% / 51%
- Nombre moyen d'enfants: 0.0

COMPORTEMENT D'ACHAT
- Nombre moyen de transactions/an: 206
- Ticket moyen: 55.92 €
- Catégorie dominante: ESSENTIE

- 2108 clients avec dépenses extrêmes (>31 020.21 ou <-9 909.76)

PROFILS REMARQUABLES :

ESSENTIEL (SUR-CONSOMMATION)
- Taille du groupe: 28.0% du segment 'Familles'
- Comportement: Alloue 39.1% de son budget à cette catégorie.
- vs la norme du segment: 24.4%
- Écart: +14.7 points de pourcentage.

FIGURE 2.8 – Profil détaillé du segment 65+ ans

Le segment des retraités révèle une vulnérabilité économique importante :

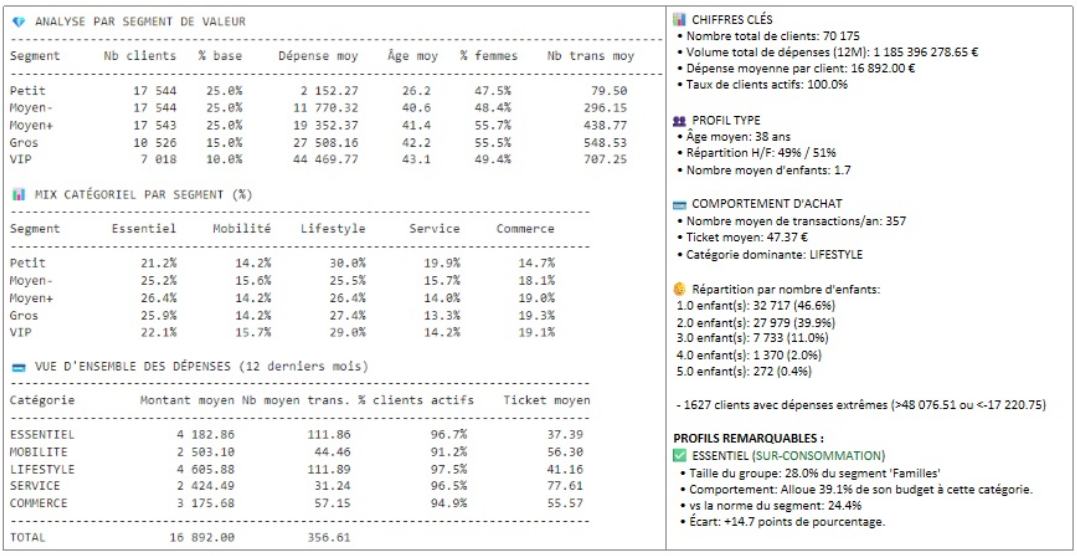
— 74 807 clients avec une forte dominance ESSENTIEL (31,2% du budget)

— 2 108 clients en situation de contrainte extrême (>50% du budget en ESSENTIEL)

— Ticket moyen le plus faible (55,92€) malgré un patrimoine apparent constitué

Familles : optimisation budgétaire sophistiquée

Segment Famille



ANALYSE PAR SEGMENT DE VALEUR

Segment	Nb clients	% base	Dépense moy	Âge moy	% femmes	Nb trans moy
Petit	17 544	25.0%	2 152.27	26.2	47.5%	79.50
Moyen-	17 544	25.0%	11 770.32	40.6	48.4%	296.15
Moyen+	17 543	25.0%	19 352.37	41.4	55.7%	438.77
Gros	10 526	15.0%	27 508.16	42.2	55.5%	548.53
VIP	7 018	10.0%	44 469.77	43.1	49.4%	707.25

MIX CATÉGORIEL PAR SEGMENT (%)

Segment	Essentiel	Mobilité	Lifestyle	Service	Commerce
Petit	21.2%	14.2%	30.0%	19.9%	14.7%
Moyen-	25.2%	15.6%	25.5%	15.7%	18.1%
Moyen+	26.4%	14.2%	26.4%	14.0%	19.0%
Gros	25.9%	14.2%	27.4%	13.3%	19.3%
VIP	22.1%	15.7%	29.0%	14.2%	19.1%

VUE D'ENSEMBLE DES DÉPENSES (12 derniers mois)

Catégorie	Montant moyen	Nb moyen trans.	% clients actifs	Ticket moyen
ESSENTIEL	4 182.86	111.86	96.7%	37.39
MOBILITE	2 503.10	44.46	91.2%	56.30
LIFESTYLE	4 605.88	111.89	97.5%	41.16
SERVICE	2 424.49	31.24	96.5%	77.61
COMMERCE	3 175.68	57.15	94.9%	55.57
TOTAL	16 892.00	356.61		

CHIFFRES CLÉS
- Nombre total de clients: 70 175
- Volume total de dépenses (12M): 1 185 396 278.65 €
- Dépense moyenne par client: 16 892.00 €
- Taux de clients actifs: 100.0%

PROFIL TYPE
- Âge moyen: 38 ans
- Répartition H/F: 49% / 51%
- Nombre moyen d'enfants: 1.7

COMPORTEMENT D'ACHAT
- Nombre moyen de transactions/an: 357
- Ticket moyen: 47.37 €
- Catégorie dominante: LIFESTYLE

Répartition par nombre d'enfants:
1.0 enfant(s): 32 717 (46.6%)
2.0 enfant(s): 27 979 (39.9%)
3.0 enfant(s): 7 733 (11.0%)
4.0 enfant(s): 1 370 (2.0%)
5.0 enfant(s): 272 (0.4%)

- 1627 clients avec dépenses extrêmes (>48 076.51 ou <-17 220.75)

PROFILS REMARQUABLES :

ESSENTIEL (SUR-CONSOMMATION)
- Taille du groupe: 28.0% du segment 'Familles'
- Comportement: Alloue 39.1% de son budget à cette catégorie.
- vs la norme du segment: 24.4%
- Écart: +14.7 points de pourcentage.

FIGURE 2.9 – Profil détaillé du segment Famille

Le segment famille (70 175 clients) présente le profil le plus sophistiqué :

— Optimisation entre ESSENTIEL (28,0%) et LIFESTYLE (26,4%)

— Forte composante SERVICE (15,7%) révélant des besoins complexes

— 1 627 clients en sur-consommation ESSENTIEL, reflétant les contraintes familiales

3.7 Analyse comportementale enrichie par les profils socio-démographiques

Segmentation MCC inversée : des comportements aux profils

L'approche inverse, partant des comportements de consommation pour analyser leur composition socio-démographique, révèle des insights complémentaires cruciaux pour la stratégie commerciale.

Résultat segmentation MCC inversée : des comportements aux profils

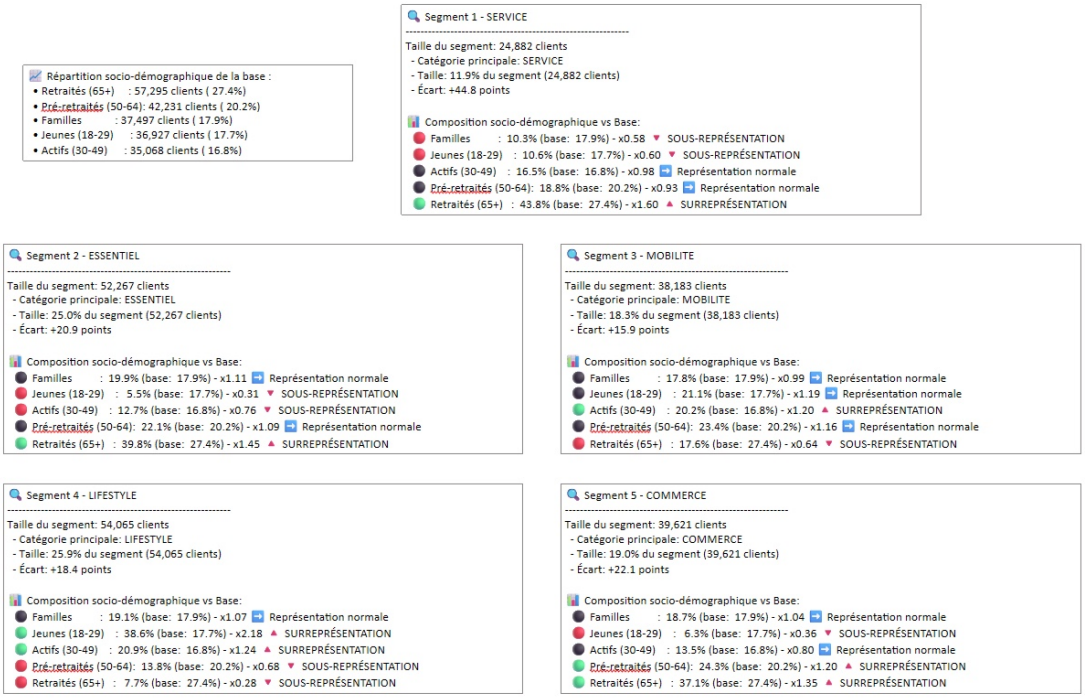


FIGURE 2.10 – Segmentation MCC avec composition socio-démographique

Segment SERVICE (24 882 clients, 11,9% de la base) :

Ce segment comportemental présente une composition générationnelle révélatrice :

— **Sous-représentation des jeunes** : 10,6% (vs 17,7% en base) avec un écart de -0,60 point

— **Surreprésentation des retraités** : 43,8% (vs 27,4% en base) avec un écart de +1,60 point

— **Équilibre relatif** pour les autres tranches d'âge

Insight stratégique : La consommation de services sophistiqués est corrélée à la maturité générationnelle, suggérant un cycle de vie de besoins bancaires complexes.

Segment ESSENTIEL (52 267 clients, 25,0% de la base) :

Composition équilibrée révélant l'universalité des dépenses contraintes :

— Répartition homogène entre toutes les tranches d'âge

— Légère surreprésentation des retraités (+1,45 point)

— Absence de biais générationnel marqué

Insight stratégique : Les dépenses essentielles transcendent les clivages générationnels, mais leur intensité varie selon les situations économiques individuelles.

Segment MOBILITÉ (38 183 clients, 18,3% de la base) :

Profil générationnel contrasté :

— **Forte surreprésentation des jeunes** : 21,1% (vs 17,7% en base) avec +1,24 point

— **Surreprésentation des actifs 30-49** : 20,2% (vs 16,8% en base) avec +1,20 point

— **Sous-représentation des retraités** : 17,6% (vs 27,4% en base) avec -0,64 point

Insight stratégique : La mobilité est un marqueur générationnel fort, concentrée sur les populations actives et en phase d'exploration.

Segment LIFESTYLE (54 065 clients, 25,9% de la base) :

Concentration générationnelle marquée :

— **Très forte surreprésentation des jeunes** : 38,6% (vs 17,7% en base) avec +2,18 points

— **Surreprésentation des actifs 30-49** : 20,9% (vs 16,8% en base) avec +1,24 point

— **Forte sous-représentation des retraités** : 7,7% (vs 27,4% en base) avec -0,28 point

Insight stratégique : Le lifestyle est l'apanage de la jeunesse et des actifs, décroissant avec l'âge selon une courbe très marquée.

Segment COMMERCE (39 621 clients, 19,0% de la base) :

Profil équilibré avec nuances :

— Répartition relativement homogène entre tranches d'âge

— Légère surreprésentation des retraités et pré-retraités

— Sous-représentation modérée des jeunes

Insight stratégique : Le commerce général représente un socle de consommation stable, moins sensible aux effets générationnels.

3.8 Synthèse des insights bidirectionnels

Convergence des approches : validation croisée

La double lecture confirme et enrichit les personas identifiés :

TABLE 2.3 – Matrice de convergence des approches

Persona identifié	**Validation socio→MCC**	**Validation MCC→socio**
Jeunes Hédonistes	Sur-conso LIFESTYLE segment 18-30	Dominance 18-30 dans segment LIFESTYLE
Jeunes Précaires	Sur-conso ESSENTIEL segment 18-30	Présence 18-30 dans segment ESSENTIEL
Actifs Équilibrés	Répartition équilibrée 30-50	Présence 30-50 dans tous segments MCC
Seniors Services	Émergence SERVICE chez 50+	Dominance 50+ dans segment SERVICE
Retraités Contraints	Sur-conso ESSENTIEL chez 65+	Surreprésentation 65+ en ESSENTIEL

Insights différenciants de l'approche bidirectionnelle

1. Universalité vs spécificité générationnelle

L'analyse comportementale révèle que certains patterns (ESSENTIEL, COMMERCE) sont trans-générationnels, tandis que d'autres (LIFESTYLE, MOBILITÉ) sont fortement corrélés à l'âge. Cette distinction est cruciale pour :

— Cibler les messages marketing selon leur sensibilité générationnelle

— Adapter les canaux de distribution aux affinités comportementales

— Anticiper les évolutions de consommation liées au vieillissement

2. Gradient vs rupture comportementale

L'approche bidirectionnelle révèle que l'évolution comportementale combine :

— Des **gradients continus** : décroissance progressive du LIFESTYLE avec l'âge

— Des **ruptures nettes** : basculement vers SERVICE après 50 ans

— Des **constantes structurelles** : persistance de l'ESSENTIEL à tous âges

3. Vulnérabilités masquées par l'âge

La double lecture révèle des situations de fragilité économique qui transcendent les clivages générationnels :

— Jeunes précaires (sur-conso ESSENTIEL malgré l'âge)

— Retraités contraints (sur-conso ESSENTIEL malgré le patrimoine)

— Actifs en transition (équilibre instable entre aspirations et contraintes)

4 Synthèse : La complémentarité des approches au service d'usages distincts

4.1 Limites méthodologiques de l'approche croisée et biais de sélection

L'analyse croisée socio-démographique × comportementale, bien qu'intellectuellement séduisante, révèle une limite fondamentale dans notre contexte bancaire. L'exploitation des données MCC introduit un biais de sélection majeur : seuls les clients détenteurs d'une carte bancaire active sont représentés dans l'analyse comportementale.

Cette restriction exclut de facto plusieurs segments de clientèle :

— Les clients patrimoniaux utilisant peu les moyens de paiement électroniques

— Les populations fragiles privilégiant les espèces

— Les clients multi-bancarisés utilisant leur carte dans un autre établissement

— Les détenteurs de comptes dormants ou peu actifs

Ce biais est particulièrement problématique pour une approche qui se veut exhaustive et représentative de l'ensemble du portefeuille client. Les 204 767 clients analysés via les données MCC ne représentent que 60% de la base totale, avec des taux de pénétration variables selon les segments d'âge et les profils socio-économiques.

4.2 La pertinence de maintenir deux approches distinctes

Face à ce constat, la décision de maintenir deux systèmes de segmentation distincts, loin d'être une limite, constitue une force méthodologique adaptée à la réalité opérationnelle bancaire.

La segmentation *precision-first* offre :

— Une couverture exhaustive de la base client (100% des clients scorés)

— Une optimisation du calcul de potentiel commercial

— Une stabilité dans le temps (les profils socio-démographiques évoluent lentement)

— Une intégration native dans les systèmes de pilotage existants

La segmentation *interpretability-first* couplé à une vision comportementale apporte :

— Une lecture dynamique des modes de vie actuels

— Une réactivité aux évolutions sociétales (post-COVID, inflation, etc.)

— Une source d'inspiration pour l'innovation produit

— Un langage commun avec les équipes marketing

4.3 Articulation opérationnelle : des cas d'usage complémentaires

La véritable innovation réside dans l'orchestration intelligente de ces deux approches selon les besoins métier :

Pour le pilotage commercial et la fixation d'objectifs :

— Utilisation exclusive de la segmentation *precision-first*

— Calcul des potentiels et priorisation des actions commerciales

— Allocation des ressources selon les segments de valeur

Pour la stratégie marketing et la communication :

— Exploitation des personas comportementaux

— Création de messages adaptés aux modes de vie identifiés

— Développement d'offres alignées sur les usages réels

Pour l'innovation produit et l'expérience client :

— Croisement ponctuel des deux visions sur des périmètres restreints

— Identification d'opportunités de création de valeur

— Test & Learn sur des segments pilotes

4.4 Perspectives : vers une approche modulaire de la segmentation

Cette dualité méthodologique préfigure une évolution plus large des pratiques de segmentation bancaire. Plutôt que de rechercher la segmentation "universelle", l'approche moderne consiste à développer un portefeuille de segmentations spécialisées, chacune optimisée pour son cas d'usage spécifique.

Cette approche modulaire présente plusieurs avantages :

— **Agilité** : Chaque segmentation peut évoluer indépendamment selon les besoins

— **Performance** : L'optimisation est ciblée sur l'objectif métier spécifique

— **Adoption** : Les utilisateurs métier comprennent et s'approprient plus facilement des outils dédiés

— **Évolutivité** : De nouvelles segmentations peuvent être ajoutées sans remettre en cause l'existant

Le chapitre suivant détaillera comment cette philosophie de modularité a guidé la conception de l'architecture applicative *Parcours 360°*, transformant ces insights méthodologiques en valeur opérationnelle tangible pour les utilisateurs finaux.

Chapitre 3

Développement de l'application web 360°

La sophistication des modèles de segmentation et des algorithmes prédictifs développés par les équipes Data n'a de valeur que si ces insights atteignent effectivement ceux qui interagissent quotidiennement avec les clients : les conseillers. Or, dans la plupart des organisations bancaires, un fossé sépare les équipes analytiques des forces commerciales. Parcours Client 360° n'est pas qu'une simple application de restitution de données : c'est un canal stratégique conçu pour diffuser progressivement l'intelligence data vers le terrain.

Le choix de commencer par la 'Ligne de vie client' – cette timeline exhaustive des interactions – n'était pas anodin. Face à la dispersion des informations entre multiples systèmes (contrats, contacts, leads, réclamations...), les conseillers perdaient un temps précieux en préparation d'entretien. En résolvant cette frustration quotidienne, nous créions les conditions d'une adoption naturelle de l'outil, établissant ainsi les fondations pour y injecter progressivement des insights plus sophistiqués.

1 L'enjeu stratégique : connecter la data au terrain

1.1 Le fossé historique entre analytics et opérationnel

Au sein du Crédit Agricole Franche-Comté, comme dans la plupart des banques régionales, les équipes Data/Marketing et le réseau commercial évoluent dans des univers parallèles. D'un côté, des analystes produisent des segmentations sophistiquées et des scores prédictifs dans leurs environnements SAS et Python. De l'autre, des conseillers jonglent entre 7 applications différentes pour préparer un simple entretien client.

Cette déconnexion génère une frustration mutuelle : les data scientists voient leurs modèles sous-exploités, tandis que les conseillers réclament des outils pratiques plutôt que des "tableaux Excel incompréhensibles". Notre défi était de créer le premier pont entre ces deux mondes.

1.2 La ligne de vie comme cheval de Troie

Le choix de la "ligne de vie client" comme première fonctionnalité n'était pas technique mais stratégique. En résolvant un irritant quotidien unanimement reconnu - la dispersion des informations client - nous établissions notre légitimité auprès du réseau. Cette approche "quick win" visait à créer l'habitude de consultation qui permettrait ensuite d'introduire progressivement des éléments plus sophistiqués.

2 Architecture technique et contraintes

2.1 Contraintes d'infrastructure héritée

Le développement de l'application a dû composer avec une infrastructure legacy présentant plusieurs limitations structurelles. Le serveur web Apache existant, déployé depuis plusieurs années au sein de la caisse régionale, ne supporte pas les fonctionnalités modernes de Server-Side Rendering (SSR). Cette contrainte technique majeure a orienté nos choix architecturaux vers une compilation statique de

l'application React. Ainsi on retrouve ci-dessous la configuration nécessaire pour cette compilation statique.

```
// next.config.js
module.exports = {
output: 'export',
images: {
unoptimized: true
},
basePath: '/parcours360',
assetPrefix: '/parcours360/',
trailingSlash: true
}
```

Listing 3.1 – Configuration Next.js pour export statique

2.2 Architecture applicative hybride

Face à ces contraintes, nous avons conçu une architecture hybride alliant technologies modernes et compatibilité avec l'existant :

Couche Frontend

L'application frontend s'appuie sur React 18 avec Next.js 13, compilée en mode statique via la commande `next export` (voir configuration ci-dessus). Cette approche génère des fichiers HTML, CSS et JavaScript purs, directement servis par Apache sans nécessiter de runtime Node.js. L'utilisation de React Context API permet une gestion d'état centralisée sans dépendance externe.

Couche Backend

Le backend PHP assure trois fonctions critiques :

1. **Authentification SSO** : Intégration avec les deux frameworks internes pour la récupération du matricule utilisateur et la validation des droits (voir code PHP ci-dessous)
2. **API REST sécurisée** : Exposition des données via des endpoints protégés par authentification

3. **Gestion des logs** : Enregistrement structuré de toutes les actions utilisateurs pour l'audit et l'analyse d'usage

```php
<?php
class SSOAuthMiddleware {
public function authenticate($request) {
// Recuperation du matricule via le premier framework
$matricule = $this->frameworkSSO->getMatricule();

// Validation des droits via le second framework
$droits = $this->frameworkDroits->validateAccess(
    $matricule,
    'PARCOURS_360'
);

if (!$droits->hasAccess()) {
    throw new UnauthorizedException();
}

return ['matricule' => $matricule, 'droits' => $droits];
}
}
```

Listing 3.2 – Middleware d'authentification SSO

2.3 Intégration avec SQL Server

La couche de données repose sur SQL Server avec des procédures stockées optimisées. L'alimentation quotidienne s'effectue via OpenQuery vers Teradata, permettant la synchronisation des données clients, contrats et indicateurs calculés.

3 Développement des fonctionnalités

3.1 Page de recherche avancée

La fonctionnalité de recherche constitue le point d'entrée principal de l'application. Il a donc été nécessaire d'implémenter un algorithme de recherche flexible

supportant plusieurs formats d'entrée, comme présenté ci-dessous :

```
const searchClient = (query) => {
const normalizedQuery = query.trim().toLowerCase();

// Detection du type de recherche
if (/^\d{14}$/.test(normalizedQuery)) {
return searchByAccountNumber(normalizedQuery);
}

// Recherche nom/prenom avec gestion des noms composes
const searchPatterns = [
normalizedQuery, // recherche exacte
normalizedQuery.split(' ').reverse().join(' '), // inversion nom/
    prenom
...generateCompoundNameVariations(normalizedQuery)
];

return searchByName(searchPatterns);
};

const generateCompoundNameVariations = (name) => {
// Gestion des noms composes avec tirets
return name.split(' ').flatMap(part =>
part.includes('-') ? [part, part.replace('-', ' ')] : part
);
};
```

Listing 3.3 – Algorithme de recherche flexible

Cette approche permet de gérer efficacement les cas complexes comme les noms composés (Jean-Pierre Dupont), les inversions nom/prénom, et les recherches par numéro de compte.

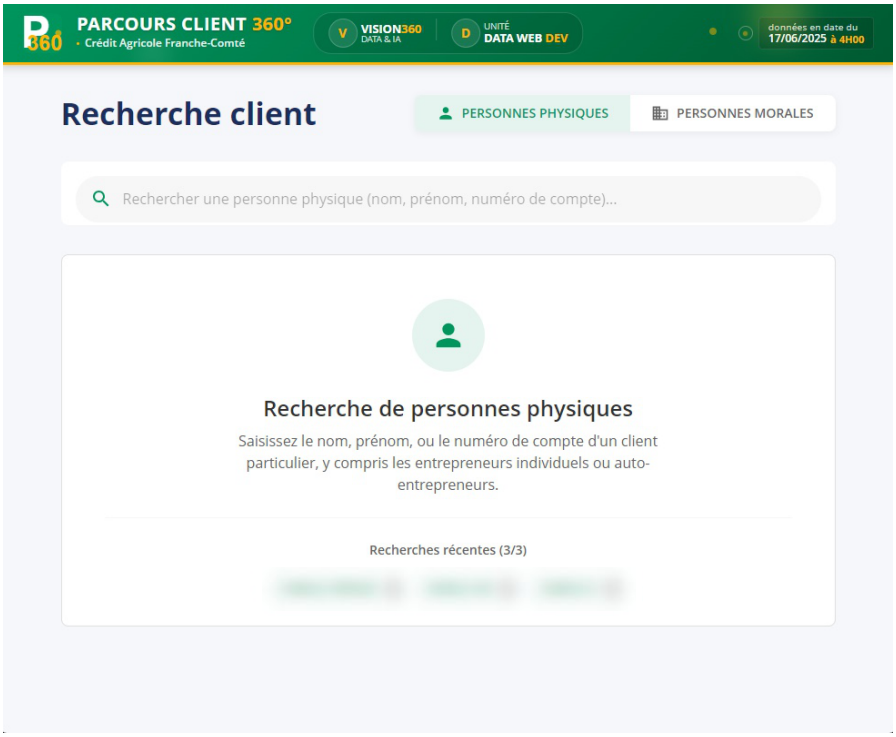


FIGURE 3.1 – Parcours 360 : Page Recherche

3.2 Dashboard client 360°

Le tableau de bord client agrège les données provenant de multiples sources pour offrir une vision holistique. L'interface est organisée en modules thématiques :

— **Synthèse client** : Informations démographiques, agence et conseiller dédié

— **Portefeuille produits** : Contrat ouverts et clos dans l'année glissante

— **Historique relationnel** : Communications, réclamations, avis Goodays

— **Indicateurs digitaux** : Note d'usage des canaux digitaux, préférences de contact

— **Actions commerciales** : Leads générés, campagnes en cours

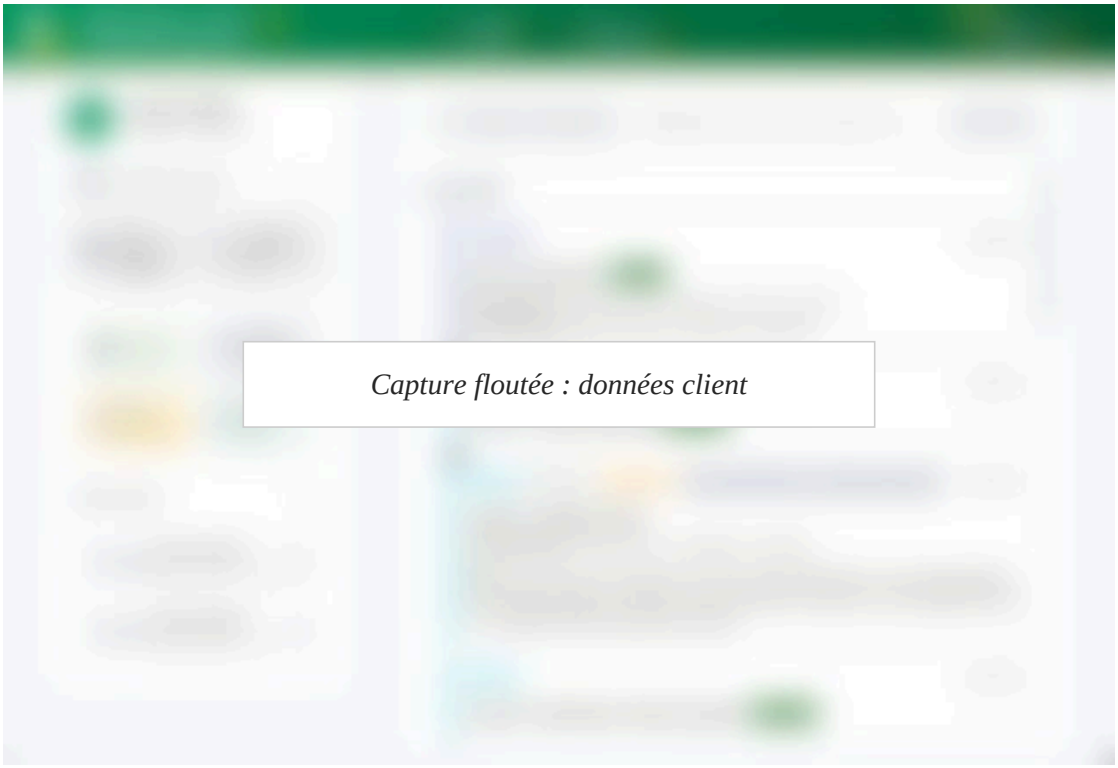


FIGURE 3.2 – Parcours 360 : Page Client

4 Déploiement et adoption

4.1 Stratégie de déploiement

Le déploiement de l'application a suivi une approche progressive pour minimiser les risques et faciliter l'adoption :

1. **Phase pilote** : Déploiement auprès d'un groupe restreint de 70 conseillers
2. **Collecte de feedback** : Formulaire envoyé par mail pour récolter les feedbacks
3. **Ajustements itératifs** : Corrections et améliorations basées sur les retours terrain
4. **Déploiement général** : Extension à l'ensemble des conseillers du réseau

4.2 Enseignements de la phase test

Les données de la phase test ont révélé un paradoxe : sur 113 utilisateurs ayant testé l'application, seuls 9 (8%) l'utilisaient régulièrement. Cette sous-utilisation initiale nous a conduits à investiguer les causes :

— **Manque de visibilité** : L'outil n'était pas intégré dans les favoris

— **Absence de formation** : Les conseillers ne percevaient pas la valeur ajoutée

— **Habitudes ancrées** : Réflexe de continuer avec les 7 systèmes habituels

Ces constats ont motivé notre plan de communication renforcé et les sessions "Micro Ouvert", dont l'impact est visible dans les métriques de production.

4.3 Accompagnement au changement

La première campagne de test sur deux mois a révélé des retours mitigés, principalement dus à un manque de communication et de formation. Pour remédier à cette situation, nous avons mis en place un plan d'accompagnement structuré :

Communication renforcée

Création d'une vidéo de présentation de 45 secondes mettant en avant les bénéfices concrets de l'outil : gain de temps, vision consolidée, identification d'opportunités. Cette vidéo, diffusée via les canaux internes, a permis de clarifier la valeur ajoutée de l'application.

4.4 Monitoring et analyse d'usage

Format des logs & Monitoring

Un système de logs structurés permet le suivi précis de l'utilisation :

```
# Exemple de log structuré
log_entry = {
"timestamp": "2025-06-17 16:03:09",
"matricule": "R000000 ",
"clientID": "00000000000000 ",
}
```

```
7
8  # Log de fin avec durée
9  log_completion = {
10 "timestamp": "2025-06-17 16:03:11",
11 "matricule": "R000000",
12 "clientID": "00000000000000",
13 }
```

Listing 3.4 – Format des logs d'utilisation

Ces logs permettent d'analyser les patterns d'usage, d'identifier les fonctionnalités les plus utilisées et de détecter d'éventuels problèmes de performance.

Métriques d'adoption : de la phase test à la production

L'analyse des logs révèle une progression encourageante entre la phase de test et le déploiement en production :

Phase de test (Mai-Juin 2025) :

— 113 utilisateurs uniques sur 38 jours ouvrés

— 441 consultations totales (11,6 consultations/jour)

— 345 clients uniques consultés

— Taux d'engagement limité : seuls 9 utilisateurs (8%) consultent régulièrement

Phase de production (Juillet 2025) :

— 165 utilisateurs uniques en seulement 11 jours ouvrés

— 385 consultations (35 consultations/jour - multiplication par 3)

— Augmentation notable de l'activité quotidienne

Cette progression de 11,6 à 35 consultations quotidiennes confirme que l'application répond à un besoin réel, une fois les freins initiaux levés par la communication et la formation.

5 Perspectives d'évolution

5.1 Intégration des scores de machine learning

La prochaine phase de développement prévoit l'intégration complète des scores de clustering et de potentiel PNB développés dans les chapitres précédents. Cette intégration nécessitera :

— Développement d'API dédiées pour exposer les scores en temps réel

— Création de visualisations interactives pour faciliter l'interprétation

— Mise en place de mécanismes d'explication des scores (explicabilité)

— Formation des conseillers à l'utilisation de ces nouveaux indicateurs

5.2 Évolutions fonctionnelles envisagées

Plusieurs évolutions sont identifiées pour enrichir l'application :

Module de recommandation

Développement d'un moteur de recommandation basé sur les scores prédictifs et l'historique client, suggérant automatiquement les produits les plus pertinents.

Intégration mobile

Adaptation de l'interface pour une utilisation sur tablette lors des rendez-vous en mobilité.

5.3 Modernisation progressive de l'infrastructure

L'expérience acquise avec ce projet ouvre la voie à une modernisation plus large de l'infrastructure :

— Migration vers une architecture de microservices

— Adoption de conteneurs Docker pour faciliter les déploiements

— Mise en place d'une API Gateway pour centraliser les accès

— Évolution vers une architecture cloud-ready

Conclusion

Parcours 360° représente bien plus qu'une réussite technique : c'est l'ouverture d'un canal de communication bidirectionnel entre l'intelligence data et le terrain commercial. En commençant par un cas d'usage simple mais à forte valeur ajoutée, nous avons créé l'habitude et la confiance nécessaires pour introduire progressivement des fonctionnalités plus avancées. Les demandes spontanées des utilisateurs ('Serait-il possible d'ajouter...', 'Ce serait génial si on pouvait voir...') confirment que la porte est désormais ouverte pour transformer leurs pratiques par la data.

Cette approche incrémentale, partant des besoins terrain plutôt que des possibilités techniques, constitue peut-être l'enseignement le plus précieux de ce projet. Dans un secteur traditionnel comme la banque régionale, la transformation digitale passe d'abord par la création de ponts humains et organisationnels.

Chapitre 4

Gestion de projet et évolution des priorités

Cette mission d'alternance m'a confronté aux réalités de la gestion de projet en environnement bancaire, où les ambitions data-driven se heurtent aux contraintes organisationnelles et techniques héritées. L'expérience acquise dans la navigation entre ces écueils constitue l'un des apprentissages majeurs de cette année.

1 Méthodologie agile adaptée au contexte bancaire

1.1 Cycles itératifs courts et validation continue

Dès les premières semaines au sein de l'équipe Data Web Dev, j'ai compris que l'approche traditionnelle en cascade serait inadaptée à notre contexte. Sous la guidance de Jean-Yves Ballot, nous avons instauré des cycles de développement de 2-3 semaines, chacun ponctué d'une démonstration aux équipes métier.

Cette approche s'est révélée particulièrement pertinente lors du développement de la segmentation comportementale. Plutôt que de présenter un modèle finalisé après plusieurs mois de travail isolé, j'ai privilégié des itérations rapides. La première présentation, montrant simplement une répartition des clients par tranches d'âge, a suscité des questions enrichissantes : "Pourquoi ne pas croiser avec les revenus ?", "Comment intégrer les frontaliers ?". Ces retours ont directement orienté

les développements suivants.

1.2 Priorisation par la valeur métier immédiate

L'une des décisions structurantes fut de commencer par des "quick wins" tangibles. L'analyse des irritants quotidiens des conseillers a révélé que la préparation d'un entretien client nécessitait la consultation de 7 applications différentes. Cette problématique, certes éloignée des algorithmes de clustering sophistiqués, offrait une opportunité de créer rapidement de la valeur.

Le développement prioritaire de la "ligne de vie client" dans Parcours 360° a ainsi servi de cheval de Troie pour l'adoption future de fonctionnalités plus avancées. Cette stratégie s'est avérée payante : les conseillers, conquis par le gain de temps immédiat, sont devenus demandeurs de nouvelles fonctionnalités data-driven.

2 Gestion des contraintes et adaptation du périmètre

2.1 Navigation entre ambitions et réalités techniques

La confrontation avec l'infrastructure existante a nécessité de constants ajustements. L'impossibilité d'implémenter du Server-Side Rendering sur les serveurs Apache existants aurait pu bloquer le projet. Nous avons contourné cette limitation en optant pour une compilation statique de l'application React, solution certes moins élégante mais pragmatique.

De même, la découverte tardive que seulement 60% des clients possédaient des données MCC exploitables a remis en question notre approche initiale de segmentation croisée. Plutôt que d'abandonner, nous avons pivoté vers une stratégie duale : une segmentation exhaustive pour le pilotage commercial, une segmentation comportementale pour le marketing ciblé.

2.2 Évolution des priorités organisationnelles

L'année a été marquée par un basculement progressif des priorités de la direction. Initialement focalisée sur l'analyse pure ("Nous voulons mieux comprendre nos clients"), l'attention s'est progressivement portée sur l'opérationnalisation ("Comment les conseillers peuvent-ils exploiter ces insights ?").

Ce changement de paradigme, probablement influencé par les premiers résultats tangibles présentés, a nécessité une réorientation de mes efforts. Le temps initialement alloué à l'optimisation des hyperparamètres des modèles a été réalloué au développement d'interfaces utilisateur intuitives et à la formation des équipes.

3 Pilotage et communication du projet

3.1 Instances de gouvernance et reporting

La structure de gouvernance mise en place reflétait la nature hybride de ma position. Les points hebdomadaires avec Jean-Yves Ballot permettaient un suivi opérationnel serré, tandis que les revues mensuelles avec Bénédicte Herrmann garantissaient la rigueur académique de la démarche.

J'ai instauré un tableau de bord partagé actualisant les métriques clés : avancement des développements, taux d'adoption des solutions, feedback utilisateurs. Cette transparence a facilité les arbitrages et maintenu l'alignement entre toutes les parties prenantes.

3.2 Gestion du changement et accompagnement

L'analyse des logs durant la phase pilote a révélé un paradoxe instructif : malgré des retours verbaux positifs, seuls 8% des testeurs utilisaient régulièrement l'application. Cette dissonance m'a conduit à repenser notre approche de conduite du changement.

La mise en place de sessions "Micro Ouvert" - des démonstrations informelles de 15 minutes pendant les pauses café - s'est révélée plus efficace que les formations formelles. Ces moments d'échange direct ont permis de lever les appréhensions et de recueillir des suggestions d'amélioration précieuses.

Chapitre 5

Compétences métiers mises en œuvre

Cette mission d'alternance a mobilisé un spectre large de compétences, depuis les aspects techniques pointus du machine learning jusqu'aux soft skills nécessaires à la transformation digitale d'une organisation traditionnelle.

1 Compétences en science des données et intelligence artificielle

1.1 Maîtrise de l'écosystème Big Data distribué

L'immersion dans l'infrastructure Cloudera m'a permis de développer une expertise pratique des technologies Big Data. Au-delà de la syntaxe PySpark, j'ai appris à penser en termes de traitements distribués, optimisant les opérations pour minimiser les shuffles coûteux entre nœuds.

La contrainte des 21 workers disponibles m'a enseigné l'importance de l'efficience computationnelle. Chaque job Spark était pensé pour maximiser la parallélisation : utilisation de `broadcast` pour les petites tables de référence, partitionnement intelligent des DataFrames, cache stratégique des résultats intermédiaires.

1.2 Techniques avancées de machine learning en contexte contraint

Le développement des modèles de segmentation a nécessité une approche créative face aux contraintes. L'absence de ground truth pour valider les clusters m'a conduit à développer une méthodologie de validation croisée originale, comparant cohérence statistique (coefficient de silhouette) et pertinence métier (interprétabilité des segments).

L'implémentation du score de potentiel dynamique illustre cette approche pragmatique. Plutôt qu'un modèle black-box sophistiqué, j'ai conçu un système transparent combinant :

— Normalisation par segment sociodémographique (correction des biais)

— Benchmarking intra-cluster (identification des best practices)

— Pondération adaptive par univers produit (contextualisation sectorielle)

2 Compétences en développement et architecture logicielle

2.1 Full-stack development en environnement hétérogène

Le développement de Parcours 360° a mobilisé l'ensemble de la stack technique moderne. La maîtrise simultanée de React pour le frontend, PHP pour la couche API, et SQL Server pour la persistance reflète la polyvalence exigée dans une équipe réduite.

Plus qu'une simple juxtaposition de technologies, j'ai dû concevoir une architecture cohérente malgré l'hétérogénéité des composants. L'utilisation de React Context pour gérer l'état global, couplée à un système de cache intelligent côté PHP, a permis d'offrir une expérience utilisateur fluide malgré la latence des requêtes vers Teradata.

2.2 Sécurité et conformité en milieu bancaire

La dimension sécurité, initialement sous-estimée, s'est révélée structurante. L'intégration avec les deux frameworks SSO internes a nécessité une compréhension fine des mécanismes d'authentification. La gestion des credentials via JCEKS, imposée par les standards du groupe, m'a familiarisé avec les contraintes de sécurité entreprise.

Le respect du RGPD a également influencé les choix architecturaux : pseudonymisation des identifiants dans les logs, durée de rétention limitée, traçabilité complète des accès. Ces contraintes, loin d'être des obstacles, ont renforcé la robustesse de la solution.

3 Compétences métier et soft skills

3.1 Compréhension approfondie du domaine bancaire

L'immersion quotidienne dans l'écosystème bancaire m'a permis d'acquérir une compréhension fine des enjeux métier. Le concept de PNB, initialement abstrait, est devenu un guide concret pour prioriser les développements. La distinction entre DAV et épargne longue, les spécificités des clients frontaliers, la saisonnalité des souscriptions : autant de nuances qui ont enrichi mes modèles.

Cette acculturation s'est faite progressivement, au fil des échanges avec les conseillers et les équipes marketing. Les sessions d'observation en agence, où j'ai pu assister à de véritables entretiens clients, ont été particulièrement formatrices pour comprendre l'usage réel des outils développés.

3.2 Médiation entre mondes techniques et métiers

La compétence la plus précieuse développée est sans doute cette capacité à naviguer entre univers techniques et métiers. Traduire un coefficient de silhouette de -0.037 en "segments suffisamment distincts pour une exploitation commerciale" nécessite une gymnastique intellectuelle constante.

J'ai appris à adapter mon discours à l'audience : utiliser des métaphores pour les comités de direction ("notre segmentation est comme une carte routière : elle

indique les grandes directions sans imposer l'itinéraire"), rentrer dans les détails techniques avec l'équipe data, adopter un angle pratique avec les utilisateurs finaux.

3.3 Leadership et conduite du changement

Malgré mon statut d'alternant, j'ai progressivement endossé un rôle de leader sur les sujets data. L'organisation des "Micro Ouvert", initialement une initiative personnelle pour résoudre le problème d'adoption, est devenue un rituel d'équipe apprécié.

La gestion de la résistance au changement m'a appris la patience et l'empathie. Comprendre qu'un conseiller utilisant le même système depuis 15 ans puisse être réticent face à une nouvelle interface m'a conduit à privilégier l'accompagnement individualisé plutôt que la formation massive.

Chapitre 6

Bilan et perspectives

Au terme de cette année d'alternance, le moment est venu de dresser un bilan objectif des réalisations, d'identifier les limites rencontrées et de tracer les perspectives d'évolution pour les projets initiés.

1 Bilan des réalisations et impacts mesurés

1.1 Objectifs atteints et valeur créée

Les objectifs initiaux de la mission - "transformer les données bancaires en outils d'aide à la décision" - ont été largement atteints, quoique par des chemins parfois inattendus. La segmentation dynamique de potentiel est aujourd'hui utilisée quotidiennement par les équipes marketing pour cibler leurs campagnes. Les 262 929 clients actifs sont répartis en segments actionnables, avec des stratégies différenciées selon leur potentiel identifié.

L'application Parcours 360°, malgré un démarrage timide, connaît une adoption croissante. Le passage de 11,6 à 35 consultations quotidiennes en seulement deux mois témoigne d'une appropriation progressive par les équipes. Plus significatif encore : les retours qualitatifs des utilisateurs mentionnent un gain de temps de 5 à 10 minutes par préparation d'entretien, soit près d'une heure par jour pour un conseiller actif.

1.2 Transformation culturelle amorcée

Au-delà des métriques quantitatives, cette mission a contribué à amorcer une transformation culturelle plus profonde. L'équipe marketing, initialement sceptique face aux approches data-driven, demande désormais systématiquement "ce que disent les données" avant de lancer une campagne.

Les conseillers, de leur côté, commencent à intégrer les notions de potentiel et de segmentation dans leur approche commerciale. Des phrases comme "Ce client est dans le segment À Développer, je vais lui proposer une offre épargne" témoignent de l'appropriation progressive des concepts introduits.

2 Limites identifiées et axes d'amélioration

2.1 Limites techniques et méthodologiques

L'honnêteté intellectuelle impose de reconnaître les limites des solutions développées. Le biais de sélection lié aux données MCC (60% de couverture) reste une faiblesse structurelle de notre approche comportementale. Les clients les plus fragiles ou les plus patrimoniaux, souvent moins utilisateurs de cartes bancaires, sont sous-représentés dans nos analyses.

Les contraintes d'infrastructure ont également bridé nos ambitions. L'impossibilité d'implémenter des modèles temps réel ou des architectures événementielles limite la réactivité des systèmes. Un client changeant brutalement de comportement ne sera identifié qu'au prochain batch mensuel.

2.2 Limites organisationnelles

Le fossé entre équipes data et réseau commercial, bien qu'amoindri, persiste. Sur les 1000+ conseillers du réseau, seuls 165 ont testé l'application, et une fraction encore plus réduite l'utilise régulièrement. Cette adoption partielle limite l'impact potentiel des solutions développées.

La gouvernance data reste également embryonnaire. L'absence de data steward dédié entraîne des incohérences dans les référentiels, compliquant les analyses cross-

systèmes. Les initiatives restent portées par des individualités motivées plutôt que par une stratégie data d'entreprise structurée.

3 Perspectives d'évolution et recommandations

3.1 Roadmap technique à court terme

Les bases posées cette année ouvrent des perspectives d'évolution prometteuses. L'intégration des scores de machine learning directement dans Parcours 360° est planifiée pour le trimestre suivant. Cette évolution transformera l'application d'un simple outil de consultation en véritable assistant intelligent.

La migration progressive vers une architecture cloud-native, bien qu'encore lointaine, se dessine. Les POC réalisés sur des environnements sandbox ont démontré les gains potentiels en termes de scalabilité et de coûts. Cette évolution nécessitera cependant une transformation profonde des mentalités et des processus.

3.2 Vision stratégique à moyen terme

Ma recommandation principale porte sur la nécessité de structurer une véritable stratégie data au niveau de la caisse régionale. La création d'un poste de Chief Data Officer, rattaché directement à la direction générale, donnerait l'impulsion nécessaire pour passer d'initiatives isolées à une transformation systémique.

L'investissement dans la formation continue des équipes constitue un autre levier critique. Le fossé de compétences data ne se comblera que par un effort soutenu d'acculturation, depuis les conseillers jusqu'au comité de direction.

3.3 Apport personnel et projection professionnelle

Cette expérience d'alternance a profondément façonné ma vision du métier de data scientist. J'ai compris que la valeur ne réside pas dans la sophistication des modèles mais dans leur appropriation par les utilisateurs finaux. Cette conviction orientera mes choix professionnels futurs vers des rôles hybrides, à l'interface entre technique et métier.

Les compétences développées - tant techniques que relationnelles - constituent un socle solide pour évoluer vers des fonctions de data product manager ou de consultant en transformation digitale. La capacité démontrée à naviguer en environnement contraint et à créer de la valeur malgré les limitations est un atout différenciant sur le marché du travail.

Conclusion du mémoire

Ce mémoire a retracé le parcours d'une année d'alternance riche en apprentissages et en défis. De la conception d'algorithmes de segmentation innovants au déploiement d'applications utilisées quotidiennement, chaque étape a contribué à transformer progressivement la culture data du Crédit Agricole Franche-Comté.

Les succès obtenus - adoption croissante des outils, appropriation des concepts par les métiers, premiers gains mesurables - ne doivent pas occulter l'ampleur du chemin restant. La transformation digitale d'une banque régionale est un marathon, non un sprint. Les fondations posées cette année ne prendront leur pleine valeur que si elles sont consolidées et étendues dans la durée.

L'expérience acquise confirme ma conviction que le futur de la data science réside dans sa démocratisation. Les data scientists de demain ne seront plus des experts isolés mais des facilitateurs, construisant des ponts entre les mondes techniques et métiers pour créer de la valeur tangible. C'est cette vision qui guidera la suite de mon parcours professionnel.

Bibliographie

Ouvrages de référence

Aggarwal, C. C. (2015). *Data Mining : The Textbook*. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning : Data Mining, Inference, and Prediction* (2e éd.). Springer.

Provost, F., & Fawcett, T. (2013). *Data Science for Business : What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.

Transformation digitale et secteur bancaire

Bergeron, F., Croteau, A. M., Uwizeyemungu, S., & Raymond, L. (2017). *Transformation numérique de l'entreprise : Théories, modèles et stratégies*. Presses de l'Université du Québec.

Tornjanski, V., Marinković, S., Săvoiu, G., & Čudanov, M. (2015). A Need for Research Focus Shift : Banking Industry in the Age of Digital Disruption. *Econophysics, Sociophysics & Other Multidisciplinary Sciences Journal*, 5(3), 11-15.

Shin, L. (2019). *La révolution Fintech : Comment la technologie transforme les services financiers*. De Boeck Supérieur.

Segmentation client et machine learning

Baesens, B., Viaene, S., Van den Poel, D., Vanthienen, J., & Dedene, G. (2002). Bayesian neural network learning for repeat purchase modelling in direct marke-

ting. *European Journal of Operational Research*, 138(1), 191-211.

Berry, M. J., & Linoff, G. S. (2004). *Data Mining Techniques : For Marketing, Sales, and Customer Relationship Management* (2e éd.). Wiley.

Han, J., Kamber, M., & Pei, J. (2011). *Data Mining : Concepts and Techniques* (3e éd.). Morgan Kaufmann.

Kumar, V., & Reinartz, W. (2012). *Customer Relationship Management : Concept, Strategy, and Tools* (2e éd.). Springer.

Ngai, E. W., Xiu, L., & Chau, D. C. (2009). Application of data mining techniques in customer relationship management : A literature review and classification. *Expert Systems with Applications*, 36(2), 2592-2602.

Big Data et architectures distribuées

Karau, H., Konwinski, A., Wendell, P., & Zaharia, M. (2015). *Learning Spark : Lightning-Fast Big Data Analysis*. O'Reilly Media.

Leskovec, J., Rajaraman, A., & Ullman, J. D. (2014). *Mining of Massive Datasets* (2e éd.). Cambridge University Press.

Marz, N., & Warren, J. (2015). *Big Data : Principles and best practices of scalable real-time data systems*. Manning Publications.

White, T. (2015). *Hadoop : The Definitive Guide* (4e éd.). O'Reilly Media.

Gestion du changement et adoption technologique

Autissier, D., & Moutot, J. M. (2016). *Méthode de conduite du changement : Diagnostic, accompagnement, performance* (4e éd.). Dunod.

Kotter, J. P. (2012). *Leading Change*. Harvard Business Review Press.

Rogers, E. M. (2003). *Diffusion of Innovations* (5e éd.). Free Press.

Venkatesh, V., Morris, M. G., Davis, G. B., & Davis, F. D. (2003). User acceptance of information technology : Toward a unified view. *MIS Quarterly*, 27(3), 425-478.

Méthodologies agiles et gestion de projet

Beck, K., Beedle, M., Van Bennekum, A., Cockburn, A., Cunningham, W., Fowler, M., ... & Thomas, D. (2001). *Manifeste pour le développement Agile de logiciels*. Agile Alliance.

Schwaber, K., & Sutherland, J. (2017). *The Scrum Guide*. Scrum.org.

Takeuchi, H., & Nonaka, I. (1986). The new new product development game. *Harvard Business Review*, 64(1), 137-146.

Protection des données et conformité

Commission Nationale de l'Informatique et des Libertés (2018). *Guide pratique RGPD : Sécurité des données personnelles*. CNIL.

Goddard, M. (2017). The EU General Data Protection Regulation (GDPR) : European regulation that has a global impact. *International Journal of Market Research*, 59(6), 703-705.

Articles spécialisés secteur bancaire français

Banque de France (2023). *La transformation digitale du secteur bancaire français*. Rapport annuel de l'Observatoire de la sécurité des moyens de paiement.

Sahut, J. M., & Kucerova, Z. (2022). La transformation digitale des banques régionales : enjeux et perspectives. *Revue Française de Gestion*, 48(304), 11-29.

RÉSUMÉ

Ce mémoire présente la conception d'un écosystème data pour une banque régionale, visant à valoriser les données clients dans un contexte d'infrastructure hybride combinant systèmes hérités et technologies Big Data. Trois contributions majeures sont développées : une approche innovante de segmentation client conciliant précision algorithmique et interprétabilité métier, une application web offrant une vision client unifiée, et une méthodologie agile favorisant l'adoption progressive. Les résultats démontrent une transformation culturelle amorcée et une appropriation croissante des outils, soulignant l'importance des synergies entre expertise technique et opérationnelle pour créer de la valeur tangible dans un environnement traditionnel.

Mots-clés : Transformation digitale bancaire, Segmentation client, Machine learning, Big Data, Développement web, Conduite du changement, Infrastructure hybride, Data valorisation

ABSTRACT

This thesis presents the design of a data ecosystem for a regional bank, aiming to leverage customer data within a hybrid infrastructure combining legacy systems and Big Data technologies. Three key contributions are developed : an innovative customer segmentation reconciling algorithmic precision and business interpretability, a web application providing a unified customer view, and an agile methodology enabling progressive adoption. Results demonstrate an initiated cultural shift and growing tool adoption, highlighting the importance of bridging technical and operational expertise to create tangible value in a traditional environment.

Keywords : Banking digital transformation, Customer segmentation, Machine learning, Big Data, Web development, Change management, Hybrid infrastructure, Data valorization